



EÖTVÖS LORÁND TUDOMÁNYEGYETEM

INFORMATIKAI KAR

PROGRAMOZÁSELMÉLET ÉS SZOFTVERTECHNOLÓGIAI
TANSZÉK

Ekvivalens Python forráskód-párok generálása

Témavezető:

Szalontai Balázs
doktorandusz

Szerző:

Verebics Péter
programtervező informatikus BSc

Budapest, 2024

Tartalomjegyzék

1. Bevezetés	3
2. Felhasználói dokumentáció	5
2.1. Futtatási környezet	5
2.2. Adatbázis beállítása	5
2.3. Adathalmazt generáló CLI	6
2.4. Átalakításokat szemléltető GUI	7
2.4.1. Alkalmazás indítása	7
2.4.2. Alkalmazás felülete	7
2.4.3. Refaktoráló nézet	8
2.4.4. AST-k vizualizálása	10
2.4.5. Adatbázis-böngésző nézet	10
3. Fejlesztői dokumentáció	12
3.1. Csomagok	12
3.2. A transformations csomag	13
3.2.1. Az <i>ast</i> modul	13
3.2.2. Az átalakítások működése	16
3.2.3. Szabályok	17
3.2.4. <i>In-place</i> szabályok	17
3.2.5. <i>For</i> szabályok	20
3.2.6. API az átalakítások alkalmazásához	25
3.3. A client csomag	26
3.4. A model csomag	27
3.5. Az app csomag	28
3.5.1. Állapotmodell	28
3.5.2. Nézetek	30
3.5.3. Vezérlők	31

3.6. Modulok	32
3.7. Tesztelés	33
3.7.1. Egységtesztek	33
3.7.2. Tesztelés a <i>QuixBugs</i> segítségével	36
4. Összegzés	38
Köszönetnyilvánítás	39
Irodalomjegyzék	39
Ábrajegyzék	42
Táblázatjegyzék	43
Forráskódjegyzék	44

1. fejezet

Bevezetés

Szakdolgozatom témája Python forráskódok átalakítása, és ezen átalakítások szemléltetése. A motiváció az átalakítások mögött egy olyan adathalmaz generálása amiben ekvivalenciával felcímkézett forráskód-párok szerepelnek. Egy ilyen adathalmazt felhasználhatunk egy mélytanuló neuronháló tanítására, ami forráskód-párok ekvivalenciáját dönti el.

Az ekvivalencia eldöntése fontos feladat, mivel egyre több, kódokat gépi tanulással refaktoráló eszköz létezik. Ezek az eszközök egy kód refaktorálására adott prompt hatására sokszor a kód jelentését is megváltoztatják, ami nem felel meg a refaktorálás definíciójának (egy átalakítás akkor refaktorálás, ha szemantikusan ekvivalens az átalakított kóddal).

A forráskód hasonlóság témája egy sokat kutatott terület. Ezen belül a forráskódok közti ekvivalencia vagy funkcionális hasonlóságok felismerésére gyakran használnak mélytanuláson alapuló módszereket [1, 2, 3, 4].

Egy ekvivalenciát eldöntő neuronháló képes lenne kiszűrni a szemantikusan nem ekvivalens átalakításokat, ezzel javítva a gépi tanulást használó refaktoráló eszközök hatékonyságán. Tehát ekvivalens és nem ekvivalens kódokat generálva felépíthetünk egy adathalmazt, ami ekvivalenciával felcímkézett kódpárokat tartalmaz, és alkalmas egy fent leírt neuronháló tanítására.

Az általam implementált átalakítások absztrakt szintaxisfák (AST-k) módosításával működnek. Egy forráskód fordítása közben a szintaktikus elemző előállítja a kód AST-jét, ami a kódot egy fa adatstruktúrával reprezentálja.

Az AST-nek a szemantikus elemzésben van szerepe, de használhatjuk kódok átalakítására is, mivel visszaalakítható forráskóddá.

Az általam megvalósított átalakítások a Python *ast* modult [5] használják, amely része a Python standard könyvtárának.

Az átalakításokat elvégzéséhez szabályokat definiáltam. Átalakításkor a Python kódból létrehozott AST-n végrehajtunk egy szabályt alkalmazó függvényt. Ez a függvény a szabály segítségével megváltoztatja az AST-t, amit ha visszaalakítunk forráskóddá, egy megváltozott Python kódot kapunk.

A szakdolgozatomban ekvivalens és nem ekvivalens átalakításokhoz is definiálok szabályokat. Egy átalakítás akkor tekinthető ekvivalensnek, ha a kód szemantikáját nem változtatja meg. Például a Python-ban is teljesül a számok körében a szorzás kommutatív tulajdonsága. Tehát, ha egy Python kódban két szám szorzásánál a bal és jobb operandust megcseréljük, akkor a szorzás eredménye nem változik, vagyis ez az átalakítás ekvivalens.

Az adathalmazban az ekvivalens kódok generálásához saját szabályok mellett a *ruff* Python linter és formatter [6] szabályait is felhasználtam. A *ruff* már létező Python lintereket implementál Rust programozási nyelven, így sok más Python refaktoráló eszköz szabályait is képes elvégezni, amelyek tökéletesek az általam implementált szabályok kiegészítésére.

A szakdolgozatom következő fejezeteiben az adathalmaz generálására és az átalakítások szemléltetésére alkalmas szoftver használatát és működését részletezem.

2. fejezet

Felhasználói dokumentáció

Az általam fejlesztett szoftver két felhasználói felülettel rendelkezik. Az egyik egy parancssoros (CLI) program az adathalmaz generálásához, a másik egy grafikus (GUI) alkalmazás az átalakítások szemléltetéséhez, és az adathalmaz böngészéséhez. Mindkét alkalmazás felületének nyelve angol.

2.1. Futtatási környezet

A szoftver egy Python 3.10-es vagy újabb verziójú Python értelmezővel futtatható. Futtatás előtt a szoftver függőségeit installálni kell a *pip* csomagkezelővel. Ezt a legegyszerűbben a szoftver forráskódjának könyvtárából tehetjük meg, a következő parancs kiadásával:

```
$ pip install --editable .
```

2.2. Adatbázis beállítása

Az adathalmaz generálásához szükség van egy *mongodb* adatbázis kliensre [7]. Az adatbázis kiszűri a kódpárok generálása közben a duplikált kódokat, és az adatok lekérdezését is megkönnyíti.

Az adatbázis elérését a forrás könyvtárában a *config/default.ini* útvonal alatt található konfigurációs fájlban lehet beállítani. Egy adatbázist három paraméter határoz meg: *host*, *port*, *database* (az adatbázis neve). Ha szükséges a konfigurációs fájl alapértékeit átírhatjuk.

2.3. Adathalmazt generáló CLI

A szoftver CLI alkalmazásával van lehetőségünk az adathalmaz generálására egy adott csv fájlban található kódokból vagy egy könyvtárban található forrásfájlokból. Adathalmazt a következő paranccsal generálhatunk:

```
$ python -m source.persistor <mode> <path>
```

A parancs paraméterei a következők:

1. *mode* - az adatok forrásának típusa, lehetséges értékek:
 - *csv* - csv fájlból olvassa a forrásfájlok tartalmát
 - *dir* - könyvtárból rekurzívan olvassa a forrásfájlokat
2. *path* - az adatok forrásának elérési útvonala

Ha megadtuk a `peristor` parancsot, a program megpróbálja a forráskódok olvasását, ha az input nem megfelelő, akkor leáll. Futtatás közben a program kiírja az éppen feldolgozott forráskóddal kapcsolatos információkat, például a kódon végzett átalakítások számát, és azt, hogy el tudta-e menteni az átalakítások eredményeit.

```
reading csv, be patient this might take a while...
-----[0]
No changes to save.
-----[1]
Fixed 13 errors.
1 file reformatted
1 file reformatted
1 file reformatted
Inserted 3 changes on hash f3842737e0fe9141df61f299c99e65d9b20a41ae3c76644ef663483aec8aeb31.
-----[2]
Fixed 12 errors.
1 file reformatted
1 file reformatted
1 file reformatted
Inserted 3 changes on hash bdd72cdcf458519e9e88afa499c0e6363e427fa7ea8c9fe5484a426bbed40c1.
```

2.1. ábra. A CLI alkalmazás futás közben

Ha a program végigolvasta a csv fájlt vagy a könyvtárban található forrásfájlokat, leáll. Amikor a program megállt, a forráskód-párok már az adatbázisban vannak, a *mongoexport* eszköz segítségével az adatbázisból a forráskód-párokat egy csv fájlba exportálhatjuk.

2.4. Átalakításokat szemléltető GUI


A szoftver GUI alkalmazása szemlélteti az átalakításokat. Kipróbálhatunk vele egy vagy több átalakító szabályt, vizualizálhatjuk kódok absztrakt szintaxis fájt, és az adatbázisba bekerült átalakítások eredményét is megnézhetjük.

2.4.1. Alkalmazás indítása

Az alkalmazás a forrás könyvtárából indítható a következő paranccsal:

```
$ python -m source
```

A parancs kiadása után a felugró ablakban beállíthatjuk az adatbázis kapcsolathoz szükséges paramétereket: a *host*, *port* illetve *database* értékeit (lásd 2.2. ábra). A *Connect* gombra kattintva az alkalmazás adatbáziseléréssel indul, ha a megadott adatbázishoz 10 másodperc alatt kapcsolódni tud, különben adatbáziselérés nélkül fog elindulni. Adatbáziselérés nélkül a *Launch Now* gombbal indíthatjuk az alkalmazást.



2.2. ábra. Az alkalmazást indító ablak

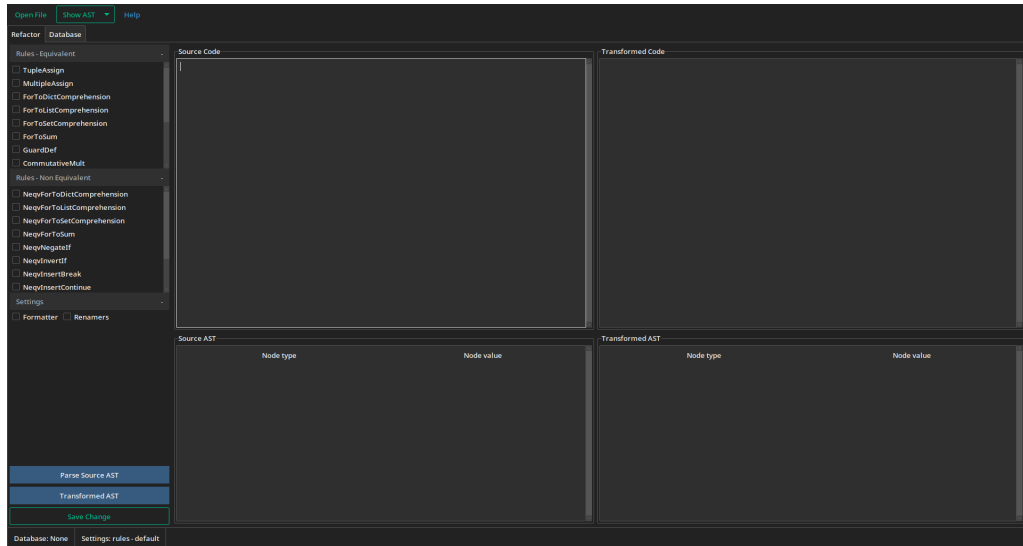
2.4.2. Alkalmazás felülete

Az GUI alkalmazás felülete funkciók szerint két fő nézetre osztható, a refaktoráló és az adatbázis-böngésző nézetre. A menü gombjai és az állapotsor szövegei a két fő nézeten kívül helyezkednek el.

A refaktoráló nézetben (*Refactor* tab) egy kódon ekvivalensen és nem ekvivalensen átalakító szabályokat próbálhatunk ki, és elmenthetjük a szabályok által végzett átalakítások eredményeit. Az adatbázis-böngésző (*Database* tab) nézetben az adatbázisba bekerült kód párokat tekinthetjük meg.


2.4.3. Refaktoráló nézet

Indítás után a felhasználót a refaktoráló nézet fogadja. Egy Python forráskód átalakításához a kódot begépelhetjük a *Source Code* szöveges input mezőbe, vagy egy *.py* kiterjesztésű fájlból is betölthetjük a menüben látható *Open File* gombra kattintva.




2.3. ábra. Refaktoráló nézet az indítás után

Az átalakítás előtt a begépelte vagy betöltött forráskódból létre kell hozni egy AST-t az elemező (parser) futtatásával, ezt a *Parse Source AST* gombbal tehetjük meg. Ha a megadott forráskódban szintaxis hiba található, vagy valami egyéb okból kifolyólag nem elemezhető, akkor az alkalmazás ezt jelzi egy felugró párbeszéd-ablakkal. Akkor is jelez, ha parse-olás nélkül klikkelünk az átalakító gombra.



(a) elemzési hiba esetén

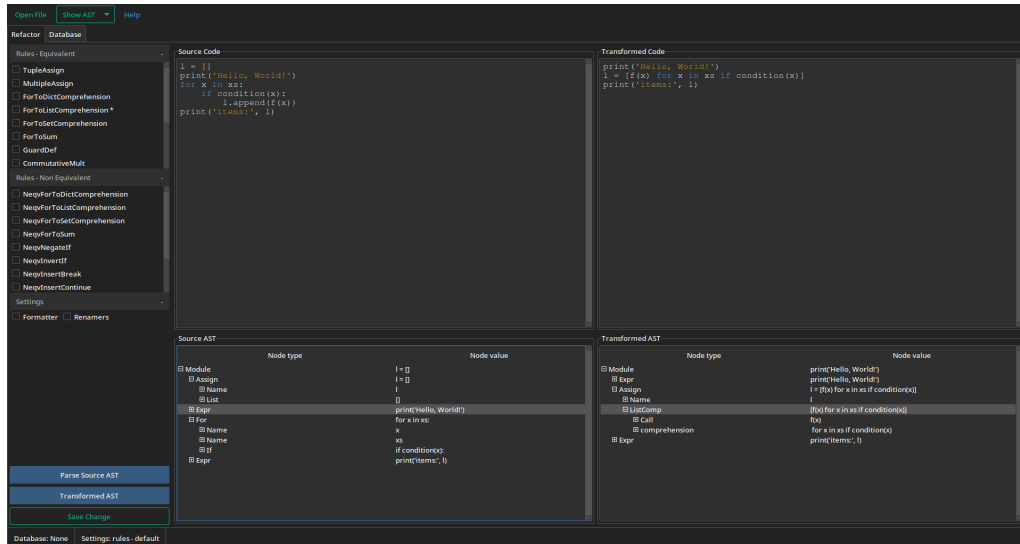


(b) hiányzó AST esetén

2.4. ábra. Hibákat jelző párbeszéd-ablakok

Sikeres elemzés után az AST felépítését a *Source AST* fa nézetben láthatjuk, az első oszlopban a csúcs típusa, a második oszlopban a csúcs szintaxis fájából generált kód látható.

Elemzés után a fát átalakíthatjuk a *Transform AST* gombra kattintva, ekkor az átalakított fa megjelenik a bal oldali *Transformed AST* fa nézetben, az átalakított fából generált kód pedig a *Transformed Code* readonly szövegdobozban.



2.5. ábra. Példa egy átalakítás eredményére

Az alkalmazás összesen 28 átalakító szabályt használ, ezek közül 16 ekvivalens és 12 nem ekvivalens eredményt állít elő. Az alkalmazás indításakor az összes ekvivalens szabály ki van választva, ez az alkalmazás alapbeállítása, amit a *'rules - default'* felirat jelez az állapotsorban.

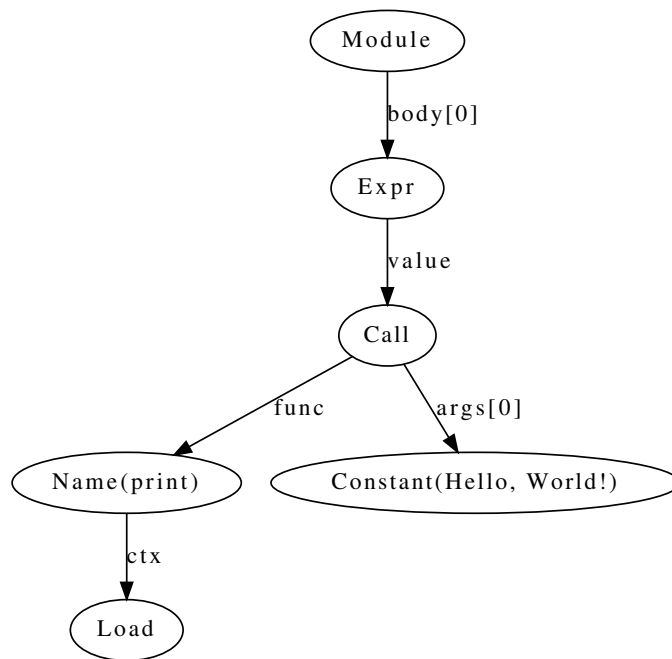
Lehetőségünk van általunk választott szabályok alkalmazására is. A szabályok listája a bal oldali panelen látható. Minden szabály előtt van egy checkbox amivel a szabályt kiválaszthatjuk. Lehetőségünk van egy vagy több szabály kiválasztására is, így könnyen tesztelhetjük egy szabály működését. Ha vannak kiválasztott szabályok, azt a *'rules - custom'* felirat jelzi az állapotsorban.

Átalakításkor a szabályok a bal oldali panelen látható sorrendben, fentről lefele kerülnek végrehajtásra. A panelen a szabályokon kívül található még két checkbox is, ezekkel a *ruff* formatter és az átnevező átalakítások alkalmazását tudjuk beállítani.

Miután átalakítottunk egy forráskódot, kimenthetjük az átalakítás eredményét az adatbázisba, ha van adatbázis kapcsolat. Ezt a refaktoráló nézet bal alsó sarkában elhelyezkedő *'Save Change'* gombra kattintva tehetjük meg. Ha az átalakítást adatbázis kapcsolat hiánya miatt nem lehet elmenteni, akkor azt az alkalmazás párbeszéd-ablakban jelzi.

2.4.4. AST-k vizualizálása

Az alkalmazással vizualizálhatjuk az általunk megadott vagy az átalakított kód AST-jét. Az AST-k ábráit a *Show AST* lenyíló menügombbal készíthetjük el, a gombra klikkelve két opció közül választhatunk: a *Source* az általunk megadott kód, a *Transformed* az átalakított kód AST-jét vizualizálja. Az alkalmazás jelzi ha a kiválasztott AST még nem jött létre, különben elkészíti az AST ábráját. A kész ábrát egy felugró ablakban nyitja meg. A 2.6. ábra például az alkalmazással készült, az ábrán a *helloworld* Python kódjának AST-je szerepel:

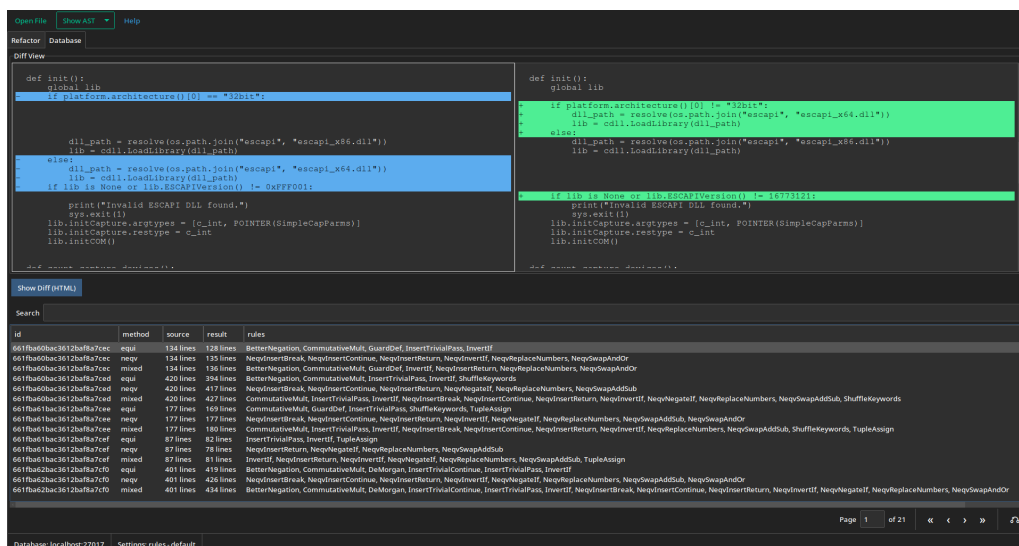


2.6. ábra. A *helloworld* program AST-je

2.4.5. Adatbázis-böngésző nézet

Ebben a nézetben megtekinthetjük az adatbázisba bekerült forráskód-párokat. A nézet csak akkor jön létre, ha az alkalmazásnak van adatbázis elérése, ha nincs, azt a nézeten a *"No database connection."* felirat jelzi. A nézet feladata a forráskód-párok listázása, és a párba állított forráskódok különbségeinek megjelenítése.

A különbségeket két forráskód között könnyen vizualizálhatjuk egy diffel, azaz olyan szövegösszehasonlító programmal, ami a szövegek közti a különbségek listáját állítja elő. A különbségeket a forráskód-párokból ezzel a módszerrel vizualizálom.



2.7. ábra. Adatbázis-böngésző nézet

A nézet tetején találhatóak a diffeket megjelenítő szövegdobozok, ezek alatt egy táblázat látható, soraiban az adatbázisba bekerült forráskód-párokkal. A táblázat soraiban található adatok sémáját a 2.1. táblázat írja le.

Oszlop	Magyarázat
<i>id</i>	az eredeti forráskód azonosítóját tartalmazó oszlop
<i>method</i>	az átalakításra használt módszerre utaló oszlop (például a szabályhalmazra)
<i>source</i>	az eredeti forráskód sorainak számát tartalmazó oszlop
<i>result</i>	az átalakított forráskód sorainak számát tartalmazó oszlop
<i>rules</i>	az átalakításnál alkalmazott szabályok listája (szöveg)

2.1. táblázat. Adatbázis-böngésző nézet táblázatának oszlopai

Ha a táblázat egy sorára, vagyis egy forráskód-párra klikkelünk, akkor a diff nézetben megjelennek az eredeti (bal oldali) és az átalakított (jobb oldali) kód közti különbségek.

A forráskód-párok böngészéséhez a táblázat feletti keresőt használhatjuk. A kereső az összes sorban és oszlopban szereplő adatok közt keres. Például megkereshetjük, hogy az adatbázisban mely forráskódokon kerültek alkalmazásra for ciklussal kapcsolatos átalakítások.

3. fejezet

Fejlesztői dokumentáció

Ebben a fejezetben az általam létrehozott szoftver implementációját mutatom be. A szoftver felépítését, a felhasznált tervezési mintákat és a fontosabb algoritmusok működését is bemutatom. A szoftver forráskódja a jövőben változhat, a frissített API dokumentáció ezért a személyes oldalamon is elérhető [8].

A szoftver forráskódja több csomagba és modulba van szervezve. Pythonban modulnak egy *.py* kiterjesztésű forrásfájlt nevezük, a csomagok pedig modulokból és alcsomagokból álló könyvtárak.

3.1. Csomagok

A bemutatott szoftver forráskódja öt csomagba van szervezve (lásd 3.1. táblázat). Minden csomag a szoftver egy jól elkülöníthető rétegét valósítja meg, például a GUI alkalmazás rétegét vagy az átalakításokért felelő réteget.

Csomag	Rövid leírás
<i>transformations</i>	átalakítások forráskódja és API az átalakításokhoz
<i>client</i>	adatbázis kliens
<i>model</i>	adatok modellezése és mentése
<i>app</i>	GUI alkalmazás csomagja
<i>tests</i>	egység és egyéb tesztek

3.1. táblázat. A szoftver fő csomagjai

Az szoftver "futtatható" fájljai és fontosabb függvényei a csomagokon kívül, külön modulokban helyezkednek el. A modulokról a 3.6. alfejezetben olvashatunk.

3.2. A *transformations* csomag

Ebben az alfejezetben ismertetem a *transformations* csomagot. Bemutatom az átalakításokhoz használt *ast* modult és az általam implementált átalakítások működését is részletezem.

3.2.1. Az *ast* modul

Az átalakításokat a Python *ast* moduljával valósítottam meg. Az *ast* modul a Python standard könyvtárban alapról megtalálható, célja az AST létrehozása a Python absztrakt-nyelvtanának alapján.

A Python absztrakt-nyelvtana a nyelv szintaxisát leíró környezetfüggetlen nyelvten, definícióját az *ast* modul dokumentációjának [5] elején találjuk.

Az absztrakt-nyelvtan definíciójában az AST csúcsainak (node-jainak) típusát az *ast.AST*-ből származó osztályok határozzák meg, ezekről szintén az *ast* modul dokumentációjának elején, a *Node classes* cím alatt olvashatunk. Egy AST-re tehát általánosan az *ast.AST* osztállyal hivatkozhatunk.

Egy Python forráskód AST-jét az *ast.parse* függvénnyel hozhatjuk létre, ami ekvivalens a Python beépített *compile* függvényének *ast.PyCF_ONLY_AST* compiler flaggel való meghívásával. Fontos, hogy AST-t csak olyan forráskódból tudunk létrehozni, ami szintaktikailag helyes, a szintaktikai hibákat az *ast.parse* a *SyntaxError* kivétellel jelzi.

Az átalakított AST-ből a kód generálására az *ast.unparse* függvényt használom. Az AST-ből való forráskód generálásra egy jó alternatíva lehet az *astor* könyvtár [9] *to_source* függvénye is.

Az *ast* modulban AST-k bejárására és átalakítására alkalmas segédfüggvények és segédosztályok is találhatóak. Az általam megvalósított átalakításokban az AST bejárását a *NodeVisitor* osztállyal, az AST átalakítását pedig a *NodeTransformer* osztállyal végzem.

A *NodeVisitor* osztály

Az AST-eket a *NodeVisitor* osztályból származtatott osztályokkal járhatjuk be.

A *NodeVisitor*-ból származtatott osztályokkal olyan, AST-vel kapcsolatos, lekérdezéseket is reprezentálhatunk, amelyek elvégzéséhez az AST bejárása szükséges.

Például egy AST-ben, az adott id-vel rendelkező, *Name* node-ok listáját a 3.1. forráskódon látható *NameVisitor* osztály *get_names* metódusával kaphatjuk meg.

```
1  class NameVisitor(NodeVisitor):
2
3      def get_names(self, root: AST, id: str) -> list:
4          self._id = id
5          self._names = []
6          self.visit(root)
7          return self._names
8
9      def visit_Name(self, node: ast.Name):
10         if self._id == node.id:
11             self._names.append(node)
```

3.1. forráskód. A *NameVisitor* osztály kódja

A *get_names* metódus paraméterei az AST (*root*) és a keresett id (*id*). Először a metódus inicializálja az *_id* és *_names* példány szintű változókat, majd elindítja a bejárást a *root*-ra. Bejárás után visszaadja a *_names*-ben összegyűjtött *Name* node-ok listáját.

A bejárást a *NodeVisitor* osztályból örökölt *visit* metódus meghívásával lehet elindítani egy AST-re. Ez a bejárás **mélységi bejárás**.

Bejárás közben a *Name* node-okat a *NodeVisitor* osztály *visit_Name* metódusának felülírásával látogatjuk meg. A meglátogatott *Name* node-ot akkor adjuk a listához, ha az id-je egyezik az *_id*-vel.

Ehhez a példához hasonlóan a *NodeVisitor*-ban az összes node típushoz létezik *visit_<node-class>* visitor metódus amit felülírhatunk.

A visitor metódus felülírásában szükség lehet a *generic_visit* meghívására. Ez akkor szükséges, ha a visitor metódushoz tartozó node típusnak lehet saját típusával megegyező gyerek node-ja (például *For* node). Ilyen esetben az összes gyerek node meglátogatásához szükséges az explicit rekurzív hívás, különben a rekurzió megáll.

NodeVisitor-ból származtatott osztállyal akkor érdemes bejárást végezni, ha mélységi bejárásra van szükségünk.

Amikor egy *NodeVisitor*-ból származtatott osztályban a bejárás rekurzív hívása történik, minden gyerekre a gyerek típusához tartozó visitor metódus kerül meghívásra, ha az létezik. Tehát, ha a gyerek típusának visitor metódusát felülírtuk, akkor a gyereket azzal fogja meglátogatni. Ha nem írtuk felül, akkor a *NodeVisitor* osztály *generic_visit* metódusa a node-okat mélységi sorrendben látogatja meg. Ezért folytat a *NodeVisitor* alaptól mélységi bejárást.

A *generic_visit*-et is felülírhatjuk. Erre a 3.2. forráskódban láthatunk példát.

```
1  class TypeVisitor(NodeVisitor):
2
3      def get_nodes(self, root: AST,
4                    node_matcher: Callable[[AST], bool]
5      ) -> list:
6          self._node_matcher = node_matcher
7          self._nodes = []
8          self.visit(root)
9          return self._nodes
10
11     def generic_visit(self, node: AST):
12         super().generic_visit(node)
13         if self._node_matcher(node):
14             self._nodes.append(node)
```

3.2. forráskód. A *TypeVisitor* osztály kódja

A 3.2. forráskódban definiált *TypeVisitor* osztály a 3.1. forráskódban definiált *NameVisitor* osztály általánosítása.

A *TypeVisitor* a bejárt AST azon a node-jait adja vissza, amikre a paraméterül kapott *node_matcher*, $AST \rightarrow bool$ típusú, függvény igaz értéket adott vissza. Ez a függvény egy node valamilyen tulajdonságát határozza meg, vagyis több típusú node-ra is működhet. Ezért kell a *generic_visit*-et használni, amivel az összes AST-ben található node-ot meglátogathatjuk.

A *NodeTransformer* osztály

Az AST-k átalakítása a *NodeTransformer* osztály segítségével valósítható meg. Ez az osztály kimondottan erre a célra használandó.

A *NodeVisitor*-hoz hasonlóan a *NodeTransformer*-ből is származtatni kell az osztályokat. Mivel a *NodeTransformer* maga is a *NodeVisitor* osztályból származik, a működése nagyon hasonló.

A bejárás szinte ugyanúgy működik mint a *NodeVisitor*-ban. Az AST-t itt is a *generic_visit* vagy *visit_<node-class>* metódusokkal járhatjuk be. A különbség az, hogy az éppen meglátogatott node-ot a *generic_visit* vagy *visit_<node-class>* metódusok visszatérési értékével lehet változtatni.

Ha a bejárás közben a node-ot meglátogató függvény visszatérési értéke *None*, akkor a meglátogatott node törlődik az AST-ből.

Ha a node-ot meglátogató függvény visszatérési értéke nem *None*, hanem egy *ast.AST* típusú node, akkor a meglátogatott node a visszaadott node-ra változik az AST-ben (ha a node-on nem akarunk változtatni akkor változatlanul visszaadjuk).

3.2.2. Az átalakítások működése

Egy átalakítás, működése (magas szinten) a következő lépésekből áll:

1. AST létrehozása egy kódból
2. AST bejárása és elemzése
3. AST bejárása és átalakítása
4. kód generálása az AST-ből

Az átalakításokat végző algoritmusok a *transformers*, *transformers_rename* és *visitors* modulokban találhatóak, ezek a modulok tartalmazzák az AST-t elemző és változtató osztályokat is.

Az általam definiált átalakítások közül egyedül a *transformers_rename* modulban található átnevezéses átalakítások nem használnak szabályokat. Minden más átalakítás szabályokra épül.

3.2.3. Szabályok

Egy szabály az AST egy node-ján alkalmazható. Alkalmazásának két lépése van, amit két, AST-n értelmezett, függvény reprezentál:

1. mintaillesztés az adott node-on:

$$\text{match}(\text{node} : \text{AST}) \rightarrow \text{Any} | \text{None}$$

2. eredmény generálása és visszaadása:

$$\text{change}(\text{node} : \text{AST}) \rightarrow \text{Any} | \text{None}$$

A két lépésnek megfelelő metódusokat a szabályok absztrakt típusát definiáló *transformations.rule.Rule* osztály deklarálja.

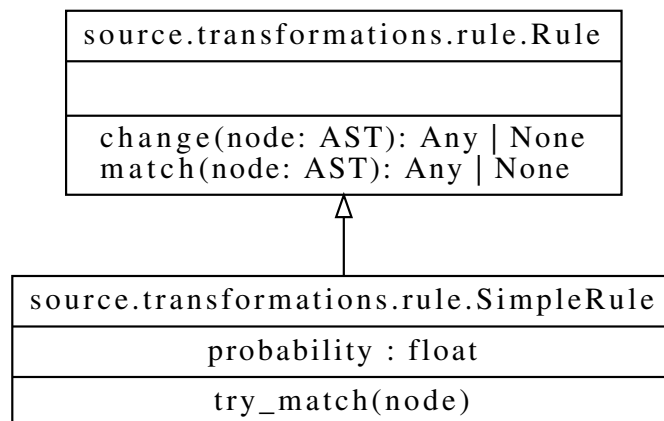
Minden szabálynak a *Rule* osztályból kell származnia és implementálnia kell az abban deklarált két absztrakt metódust.

Egy szabály önmagában nem képes egy egész AST átalakítására. Az átalakítást a *NodeTransformer*-ből származó *RuleTransformer* átalakító osztályok végzik egy szabály segítségével a *transform_ast* metódusban.

A következő alcímek alatt a két különböző szabály-típusról és az ezeket alkalmazó átalakító osztályokról olvashatunk.

3.2.4. *In-place* szabályok

Az *In-place* szabályok a *SimpleRule* absztrakt osztályból származnak, az osztály UML diagramját a 3.1. ábrán láthatjuk.



3.1. ábra. A *SimpleRule* osztály

Az *In-place* az AST egy node-ját alakítják át, ha azon a node-on sikeresen mintaillesztettek, vagyis a node-ot helyben változtatják.

Ezek az általam implementált legegyszerűbb szabályok, az *Rule*-tól örökölt *match* metódust definiálva mintaillesztenek egy node-ra. A mintaillesztés sikerességének jelentése az *In-place* szabályoknál szabályfüggő.

Egyes szabályokban (pl. az *InvertIf* szabályban) csak mintaillesztetni kell a node-ra, ezeknél a szabályoknál a *match* visszatérési értéke *bool* típusú és a mintaillesztés sikerességére utal.

Más szabályokban (pl. a *GuardDef* szabályban) megkönnyíti a dolgunkat, ha a node-ot mintaillesztés közben "dekonstruáljuk", azaz a node bizonyos attribútumait vagy gyerekeit elmentjük és visszaadjuk, hogy a *change* metódus ezeket fel tudja használni. Ezeknél a szabályoknál a *match* visszatérési értéke *None* típusú, ha a mintaillesztés sikertelen. Sikeres mintaillesztésnél a *match* az elmentett attribútumokat vagy gyerekeket adja vissza egy rendezett n-esben.

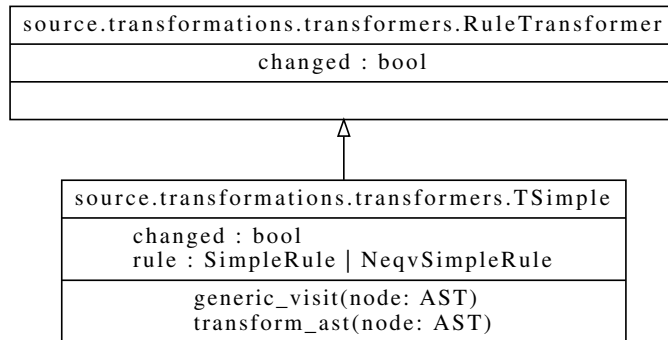
Ekvivalens és nem ekvivalens *In-place* szabályokat is definiáltam. Az ekvivalens szabályok a *rules_eqv.rules_simple* modulban, a nem ekvivalens szabályok pedig a *rules_neqv.rules_simple* modulban találhatók.

Az *In-place* szabályokban a *change* metódus feladata a node átalakítása és az átalakított node visszaadása. A *change* metódus először mintailleszt a *try_match* meghívásával. A *try_match* visszatérési értéke alapján vagy átalakítja a node-ot, vagy egy *None* visszaadásával jelzi, hogy az adott node-ot nem tudja átalakítani.

Minden *SimpleRule* osztályból származó szabály rendelkezik egy valószínűséggel változóval (*probability* a 3.1. ábrán). Erre azért van szükség, mert a nagyon egyszerű szabályokat nem biztos, hogy minden node-ra alkalmazni szeretnénk. Ennek érdekében egy *In-place* szabály létrehozásakor megadhatunk egy 0 és 1 közötti valószínűséget, ami a szabály alkalmazásának valószínűsége.

A valószínűség implementációja miatt van szükség a *try_match* definiálására is. Ez a metódus először mintailleszt a node-on. Ha a mintaillesztés sikertelen, akkor leáll. Ha a mintaillesztés sikeres, akkor generál egy 0 és 1 közötti számot, amivel a valószínűséget szimulálja. Ha a generált szám kisebb mint a szabály valószínűsége, akkor a mintaillesztést sikeresnek tekintjük, különben sikertelennek.

Az *In-place* szabályokat a *RuleTransformer* osztályból származó *TSimple* osztály alkalmazza. A *TSimple* osztály UML diagramját a 3.2. ábrán láthatjuk.



3.2. ábra. A *TSimple* átkészítő osztály

A *TSimple* működése egyszerű, a *generic_visit*-et felülírva mélységi bejárással meglátogatja az AST node-jait. Minden meglátogatott node-ra alkalmazza a *rule* példány szintű változóban található szabályt. Ha a szabály alkalmazható, akkor a node-ot átalakítja, különben változatlanul hagyja. A bejárást a *transform_ast* indítja. A bejárás végén az eredmény a *changed* bool-ban található, ami azt jelzi, hogy sikerült-e a szabályt legalább egyszer alkalmazni az AST-n.

Az *In-place* szabályok listáját a 3.2. és 3.3. táblázatokban láthatjuk. ¹

Ekvivalens in-place szabályok		
Szabály	Magyarázat	p
<i>MultipleAssign</i>	Többszörös értékadást több értékadássá alakító szabály	1.0
<i>TupleAssign</i>	Tuple értékadást több értékadássá alakító szabály	1.0
<i>GuardDef</i>	Függvény else ágbeli return utasítását early return utasítássá alakító szabály	1.0
<i>SingleIf</i>	if utasításon belül található if utasítás feltételének hozzáadása a külső if feltételéhez	1.0
<i>InvertIf</i>	if utasítást if és else ágait megfordító szabály	1.0
<i>DeMorgan</i>	De Morgan azonosságokat alkalmazó szabály	1.0
<i>DoubleNegation</i>	Dupla negációkat eltüntető szabály	1.0
<i>BetterNegation</i>	Külső negációkat bevívó szabály	1.0

¹p a szabályok alap valószínűsége

Szabály	Magyarázat	p
<i>CommutativeMult</i>	Szorzás jobb és bal operandusát felcserélő szabály	0.5
<i>ShuffleKeywords</i>	Keyword argumentumokat összekeverő szabály	0.66
<i>InsertContinue</i>	continue utasítás beszúrása a ciklus végére	0.11
<i>InsertPass</i>	pass utasítás beszúrása egy függvény definícióba	0.11

3.2. táblázat. Ekvivalens *In-place* szabályok táblázata

Nem ekvivalens in-place szabályok		
Szabály	Magyarázat	p
<i>NeqvNegateIf</i>	if feltételének negálása ágak megfordítása nélkül	0.5
<i>NeqvInvertIf</i>	if ágainak megfordítása feltétel negálása nélkül	0.5
<i>NeqvInsertBreak</i>	break utasítás beszúrása ciklus elejére	0.33
<i>NeqvInsertContinue</i>	continue utasítás beszúrása ciklus elejére	0.33
<i>NeqvInsertReturn</i>	return utasítás beszúrása ciklus elejére	0.33
<i>NeqvSwapAndOr</i>	and és or operátorok felcserélése	0.5
<i>NeqvSwapAddSub</i>	+ és - operátorok felcserélése	0.5
<i>NeqvReplaceNums</i>	Szám konstansokat átíró szabály	0.33

3.3. táblázat. Nem ekvivalens *In-place* szabályok táblázata

A szabályok alap valószínűségeit az alkalmazott szabályok gyakoriságának alapján állítottam be. Az alkalmazott szabályok gyakoriságát 1000 GitHub-ról gyűjtött forráskódon vizsgáltam meg. A gyakran alkalmazott szabályoknak kisebb, a kevesebbet alkalmazott szabályoknak nagyobb valószínűséget adtam.

A leggyakoribb szabály például az *InsertPass* volt, 1000 kódon 771-szer lett alkalmazva, ezért ennek a szabálynak kisebb valószínűséget adtam meg.

3.2.5. *For* szabályok

A *For* szabályok for ciklussal megadott alap programozási tételek megoldásából, comprehension kifejezést használó megoldásokat állítanak elő.

A comprehension egy speciális kifejezés a Python absztrakt-nyelvtanában, ami egy iterálható kifejezéstől (*iter*), egy *target*-kifejezésből (*target*) és "if" kifejezések listájából (*ifs*) áll.

Az "if" kifejezések a nyelvtan definíciójában kifejezések nem if statement-ek. Comprehension kifejezést használhatunk alap mutable adatstruktúrák (list, dict, set) vagy generátorok meghatározására.

Egy *For* átalakítás személtetéséhez tekintsük a következő feladat példáját:

1. *Példa.* Adjuk meg az $xs : \text{Iterable}$, azon elemeit egy listában, amikre a *condition* függvény teljesül (feltéve, hogy $\text{bool}(\text{condition}(x))$ az xs minden x elemére értelmes).

Az egyik megoldás, ha létrehozunk egy üres listát, majd egy for ciklussal iterálunk az xs -en és a listához adjuk azokat az elemeket amelyekre a *condition* függvény "truthy" értéket ad vissza. A "truthy" értékek olyan literálok vagy objektumok amiket boolean-á alakítva igazat kapunk.

A másik megoldás, ha a listát egy list comprehensionnel adjuk meg, ekkor a for ciklus if feltételét a list comprehension végére tesszük.

```
result = []
for x in xs:
    if condition(x):
        result.append(x)
```

3.3. forráskód. Példa megoldása for ciklussal

```
result = [
    x for x in xs
    if condition(x)
]
```

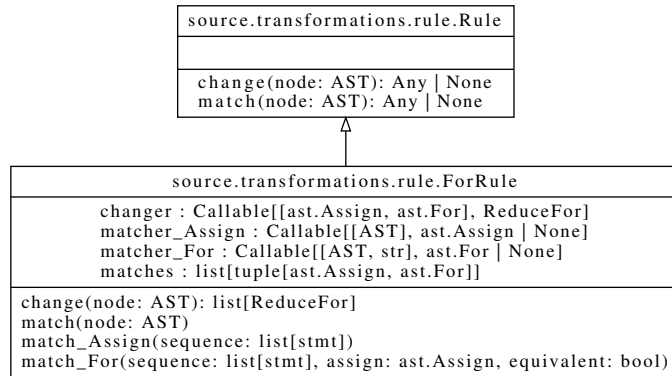
3.4. forráskód. Példa megoldása comprehensionnel

Pythonban a legtöbb esetben a második megoldás a preferált az elsővel szemben, rövidebb és általában olvashatóbb is.

A *For* szabályok célja a példához hasonló átalakítások megvalósítása. Ekvivalens és nem ekvivalens *For* szabályokat is implementáltam. A szabályok egy értékadást és egy for ciklust alakítanak comprehension-ös kifejezéssé. A szabályok közt vannak list, dict és set comprehension-né alakító szabályok, illetve számok összegének és feltételes összegének kiszámítására is van egy szabály.

A *For* szabályok a sablonfüggvény (*template method*) tervezési minta segítségével működnek. A mintaillesztést a *ForRule* osztály *match* metódusa végzi. A *match*

metódus a sablonfüggvény, a sablonfüggvény lépései pedig a *match_Assign* és *match_For* metódusok.



3.3. ábra. A *ForRule* osztály

A 3.3. ábrán látható *matcher_Assign* és *matcher_For* osztálszintű változók függvények. Ezeket a függvényeket használok a *match_Assign* és *match_For*-ban az *Assign* és *For* node-ok mintaillesztésére.

A mintaillesztésénél a statement listát tartalmazó node-okra kell mintailleszteni, ezek a Python absztrakt-nyelvtanának megfelelően azok a node-ok, amik *body*, *orelse* vagy *finalbody* attribútumokat tartalmaznak.

Az ilyen node-okat három `match` utasítással ismerhetjük fel, amik a következő esetekre mintaillesztenek:

`AST(body=[_, _, *_])`, `AST(orelse=[_, _, *_])`, `AST(finalbody=[_, _, *_])`.

Ha a node-ban van statementek listáját tartalmazó attribútum, akkor arra az attribútumra meghívjuk a *match_Assign* metódust.

A *match_Assign* először a statementek listájában szereplő node-okra meghívja a *matcher_Assign* függvényt. Ha a *matcher_Assign* sikeresen mintailleszt a node-ra, akkor a listában az utána szereplő statementeken kell mintailleszteni a *matcher_For* segítségével. Ha a *matcher_For* is sikeresen mintaillesztett akkor az átalakítást el lehet végezni a felismert *Assign* és *For* node-okon. Ilyenkor az átalakítást a felismert *Assign* és *For* párokat tartalmazó *matches* listához adjuk.

A *For* átalakítások felismerésének pszeudokódját a 1. algoritmuson láthatjuk.

1. algoritmus A *For* átalakítások felismerésének algoritmus

method ForRule::match_Assign(*statements* : list[*stmt*])

```
1: n := length(statements) - 1
2: for i in 0...n do
3:   assign := self.matcher_Assign(statements[i])
4:   if assign is not None then
5:     self.match_For(statements[i + 1 : n], assign)
6:   end if
7: end for
```

method ForRule::match_For(*statements* : list[*stmt*], *assign* : *Assign*)

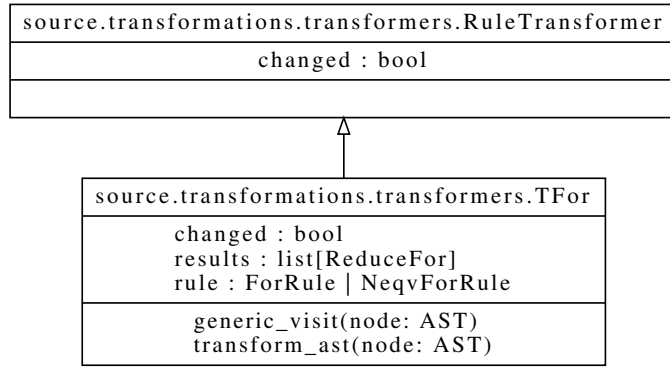
```
1: name := assign.target.id
2: for statement in statements do
3:   matched_for := self.matcher_For(statement, name)
4:   if matched_for is not None then
5:     self.matches.append((assign, matched_for))
6:     return
7:   end if
8:   if set(ids(statement)) ∩ set(ids(assign)) ≠ ∅ then
9:     return
10:  end if
11: end for
```

Ha az 1. algoritmus lefutott, akkor a megfelelő *Assign* és *For* node párokat a szabály *matches* listájában találhatjuk meg.

A *For* szabályok *change* függvénye először előállítja a *matches* listát. Ha a *matches* nem üres, akkor az elemeiből létrehozza és visszaadja a változtatásokat egy listában ami *ReduceFor* példányokat tartalmaz (lásd *change* metódus a 3.3. ábrán). A *ReduceFor* osztály egy példánya tartalmazza a törlendő *Assign* node-ot, a generált comprehension node-ot és a *For* node-ot, amit helyettesíteni kell a generált node-al.

A *For* szabályokat a *TFor* átalakító osztály segítségével lehet alkalmazni. Az átalakítások alkalmazásához az átalakító osztálynak kétszer kell bejárnia az AST-t. Az első bejárással összegyűjtjük a lehetséges változtatásokat az AST node-jain. A változásokat a *TFor* osztály *results* listájában tároljuk (lásd 3.4. ábra). A lista mindig a szabály *change* metódusa által visszaadott *ReduceFor* példányokkal bővül.

Az első bejárás után a lehetséges változtatások már a *results* listában vannak. Az AST-t újból bejárva a változtatásokat elvégezzük. A megjelölt *Assign* node-okat töröljük és megjelölt *For* node-okat a generált kifejezésre változtatjuk.




3.4. ábra. A *TFor* átalakító osztály

A *TFor* osztály *transform_ast* metódusa kétszer hívja meg a *visit*-et a paraméterül kapott node-ra. A bejárást az osztály *ageneric_visit* felülírásával végzi.

A *transformations* csomagban négy féle *For* szabályt implementáltam. Az első három szabály az üres dict, list vagy set -et inicializáló for ciklusokat, alakítja dict, list vagy set comprehension-né (a feltételes esetet is vizsgálva). A negyedik szabály a nullával inicializált, for ciklus által számolt, összeget vagy feltételes összeget alakítja egy *sum* beépített függvény hívássá.

Mind a négy fajta *For* szabálynak van ekvivalens és nem ekvivalens változata is. A különböző szabályok fajtáit a 3.5. ábrán látható osztálydiagrammon láthatjuk.



3.5. ábra. A *For* szabályok UML diagramja

3.2.6. API az átalakítások alkalmazásához

Az átalakításokat a *transformation* modul segítségével alkalmazhatjuk. A modul célja egy olyan API létrehozása amivel könnyen átalakíthatunk kódokat vagy kódok AST-jét. Az API implementálásához az absztrakt gyár (*Abstract factory*) és az építő (*Builder*) tervezési mintákat használtam fel.

Ahogy azt az előző fejezetekben részleteztem egy szabály alkalmazásához két objektumot kell létrehozni: a szabályt és az annak megfelelő átalakító osztályt. Az absztrakt gyár az átalakító osztályok és szabályok példányosításában segít.

Az absztrakt gyár mintát a *create_rule* függvény implementálja. A függvény a szabálytípusok átalakító osztályait állítja párba a szabályokkal. Egy szabálynév alapján a *create_rule* létrehozza a szabálynak megfelelő átalakító osztály példányát. Ha a megadott nevű szabály nem létezik, akkor *ValueError* kivételt dob.

Egy AST-t az átalakítás során gyakran több átalakító osztállyal is be szeretnénk járni. Például ha két szabályt szeretnénk alkalmazni, akkor az AST-t kétszer kell bejárni. A többszörös bejárások elvégzésében az építő tervezési mintát megvalósító *TransformationBuilder* osztály segít.

A *TransformationBuilder* osztály segítségével létrehozhatjuk átalakítók listáját, amivel egy AST-n több egymás utáni átalakítást (például szabályokat) hajthatunk végre. Ehhez definiáltam a *Transformer* interfészt, amit minden átalakítónak implementálnia kell. A *Transformer* interfészben csak egy metódus található, a *transform_ast*, ami az AST bejárását és átalakítását végzi. Ezt a metódust implementálják a szabályok átalakító osztályai is.

Az is gyakran előfordul, hogy nem az eredeti AST-t akarjuk átalakítani, hanem annak egy másolatát, erre a célra a *CopyTransformer* osztályt használhatjuk. A *CopyTransformer* osztályt egy AST alapján példányosíthatjuk. A megadott AST-t a *CopyTransformer* lemásolja a *deepcopy* segítségével. Az átalakításokat már a másolaton végzi a *TransformationBuilder*-t felhasználva.

3.3. A client csomag

A *client* csomag feladata az adatbáziskapcsolat és az indexek létrehozása. A kliens a *pymongo* könyvtárat használja, implementációja a *Client* osztályban van.

A szoftverben az adatbázist a *Client* osztályon keresztül érhetjük el. Például az adatbázis forráskódokat és forráskód-párokat tartalmazó kollekciói a kliensen keresztül elérhetők.

A *Client* osztály a Python-ban gyakori *monostate* [10] tervezési mintát használja, a minta a *singleton*-hoz hasonló, de több példány létrehozását is megengedi. Egy *monostate* osztálynak van egy belső (statikus) állapota, példányosításnál ezt a belső állapotot adja vissza. Ez hasznos, mert a példányok egy közös állapoton osztoznak, ami a program több részéről is elérhető.

Python-ban az objektumok állapota reprezentálható egy dict segítségével, ezért a *monostate* mintát nagyon egyszerű implementálni: a belső állapot egy dict lesz, példányosításnál a belső állapot dict-je alapján hozunk létre egy objektumot.

Client
client : MongoClient None code : Collection None code_change : Collection None
connect_client(host: str, port: int, database: str): bool get_client_info(): str set_client(client: MongoClient, database: str): bool

3.6. ábra. A *Client* osztály UML diagramja

Amikor először példányosítunk a *Client*-ből a *client*, *code* és *code_change* attribútumai *None* értékeket vesznek fel (ez a kezdetleges belső állapot).

Ha ezután meghívjuk a *connect_client* metódust az adatbázis paramétereivel és a kapcsolat 10 másodpercen belül létrejön, akkor a kapcsolat sikeres. Ekkor a *client* attribútum az adatbáziskliens, a *code* és *code_change* attribútumok pedig rendre a kódokat és kód-párokat tartalmazó kollekciók lesznek.


A kollekciók akkor is létrejönnek a kliens szintjén ha az adatbázisban még nem szerepelnek. Ebben az esetben a kollekció az adatbázisban akkor jön létre, ha a kliensen keresztül elmentünk egy dokumentumot. A kliens a szükséges indexeket definiálja az adatbázisban.

3.4. A model csomag

A *model* csomag a feladata a forráskód-párok modellezése, három modulból áll:

- *datatypes* - az adattípusokat definiáló modul
- *serializers* - az adattípusokat szerializáló modul
- *stores* - az adattípusokat elmentő modul

A csomagban két adattípust definiáltam: a *Code* és *CodeChange* típusokat. A *Code* a forráskódok modellje, a *CodeChange* pedig a forráskód-párokat modellezi. Az adatokat modellező osztályok UML diagramjait a 3.7. ábrán láthatjuk.



3.7. ábra. A model csomag osztályainak UML diagramjai

A forráskód a duplikátumok kiszűrése miatt rendelkezik saját modellel. A duplikált forráskódok szűrése azért szükséges, mert a GitHub-on található kódok jelentős része duplikátum [11], vagyis ha GitHub-ról bányászunk kódokat akkor a generált adathalmaz minőségén javíthatunk, a duplikátumok kiszűrésével.

A kódok modellje ezért a kód mellett a kód *sha256*-os hashét is tárolja. Mielőtt a kódot elmentjük az adatbázisba megnézzük, hogy a hash ütközik-e.

Ha nincs ütközés, akkor a kódot azonnal a kollekcióhoz adhatjuk, különben csak az ütköző kódokat kell összehasonlítani a duplikátumok kiszűréséhez. A hash attribútuma indexelve van a kódokat tartalmazó kollekcióban, ez biztosítja a gyors lekérdezést.


A *CodeStore* és *CodeChangeStore* osztályokkal lehet a kódokat és kódpárokat elmenteni az adatbázisba. A duplikátumok szűrését a *CodeStore* osztály *save_one* metódusa végzi. A szűrés opcionális, ha nem szeretnénk szűrést azt a *dupes* boolean paraméterrel állíthatjuk be. Ha a *dupes* igaz akkor megengedjük a duplikátumokat.

3.5. Az app csomag

Az *app* csomag feladata az átalakításokat szemléltető GUI-s alkalmazás megvalósítása. Az alkalmazás architektúrája modell-nézet-vezérlő (MVC) szerű. Egy nézet rendelkezik egy vezérlővel, a vezérlő pedig egy modellel.

A nézet feladata a GUI definiálása és frissítése, a modell feladata az adatelérés vagy az alkalmazás állapotának modellezése. A vezérlő ezt a két réteget köti össze, így a nézet nem függ a modelltől és a modell sem a nézettől.

Az alkalmazás csomagjainak UML diagramját a 3.8. ábrán láthatjuk.



3.8. ábra. Az alkalmazás csomagjai

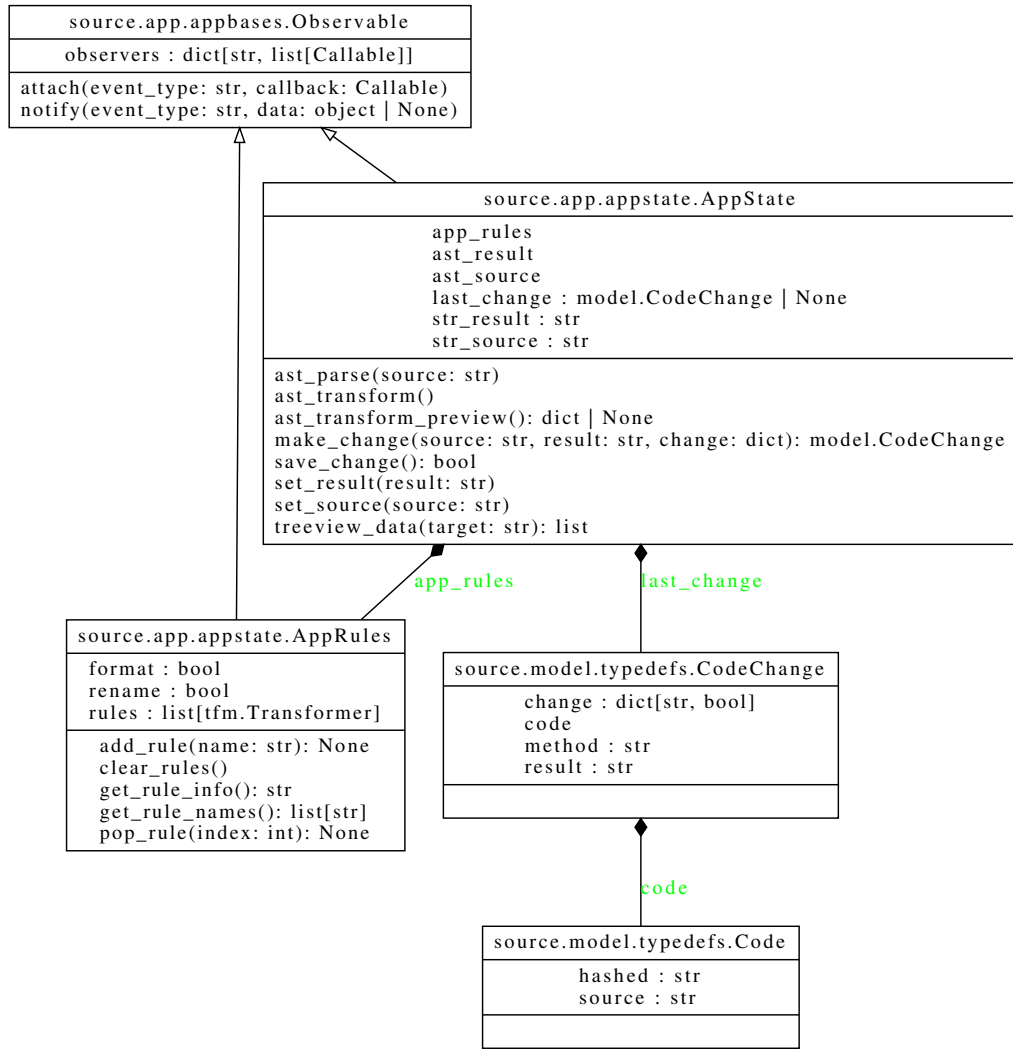
3.5.1. Állapotmodell

Az alkalmazásban kétféle modell különböztethető meg: az adatelérési modellek (lásd 3.4. szekció), és az alkalmazás állapotmodellje, ami az *app.appstate* modul *AppState* osztályában van definiálva.

Az állapotmodell a megfigyelő (*observer*) tervezési mintát használja a nézetek frissítésére. Az *AppState* osztály az *Observable* osztályból származik, ezért rendelkezik megfigyelők dict-jével (*observers*). A megfigyelők dict-je tartalmazza az esemény-eseménykezelő key-value párokat.

Ha a nézet valamelyik komponenesét az állapotmodell egy változásának hatására szeretnénk frissíteni, akkor azt az eseménykezelőt, ami frissíti, hozzárendelhetjük az állapotmodell egy eseményéhez az *app.events* modulból.

Hozzárendelni egy eseménykezelőt egy eseményhez az *Observable* osztály *attach* metódusával lehet. Ha az adott eseményt kiváltja egy változás a modellben, akkor a modell értesíti a nézeteket, vagyis az *observers*-ben az eseményéhez rendelt eseménykezelőket meghívja, a frissítéshez szükséges adatokat paraméterként továbbítva.



3.9. ábra. Állapotmodell és kapcsolódó osztályok UML diagramjai

Az állapotmodel UML diagramját a 3.9. ábrán látjuk. Az alkalmazás egy állapotát a bemeneti és kimeneti AST-k, az ezekből generált kódok, az átalakításért felelő szabályok listája, és az utolsó átalakítás írják le.

Az AST-k és a belőlük generált kódok az *AppState* osztály példány szintű változói. Ezeken kívül az állapotmodell az *AppRules* és a *CodeChange* osztályok egy-egy példányát is tartalmazza, ezek rendre az átalakításért felelő szabályokat és az utolsó átalakítást tárolják.

Az *AppRules* a szabályok állapotát modellezi, szintén az *Observable*-ból származik. Ez az osztály tartalmazza a kiválasztott szabályokat a *rules* listában, a *format* és *rename* bool-okkal pedig azt tárolja, hogy az átalakított kódot kell-e formátálni és hogy az átnevezéseket végre kell-e hajtani.

Az utolsó validált átalakítást a *CodeChange* osztály egy példánya tárolja. Ahogy azt az előző alfejezetben is említettem ezzel az osztállyal, lehet elmenteni átalakításokat az adatbázisba.

A modellt az *AppState* metódusai segítségével változtathatjuk. A metódusok az AST-k átalakításáért és az utolsó átalakítás mentéséért felelnek, a modellel kapcsolatos eseményeket is ezek váltják ki.

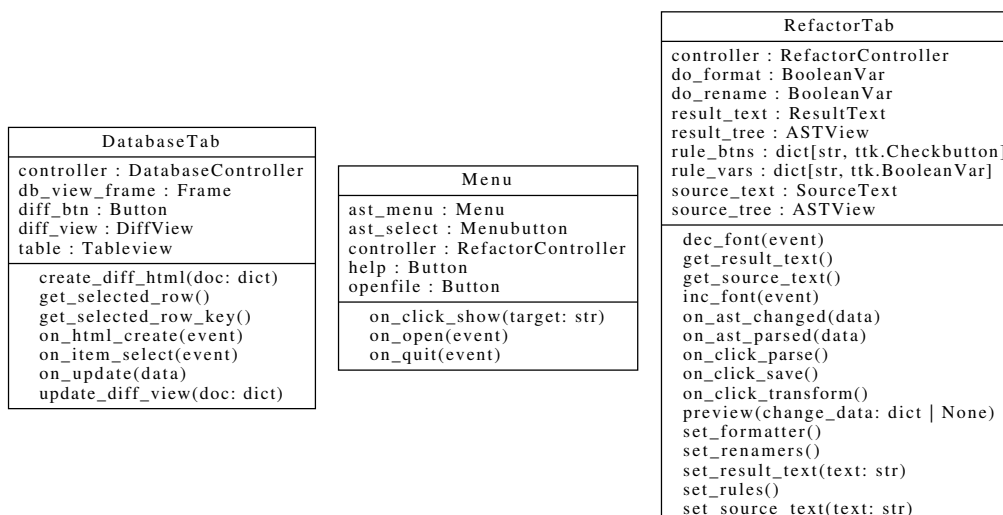
3.5.2. Nézetek

Az alkalmazás grafikus felhasználói felületének megvalósításához a Python-ban alaptól megtalálható *tkinter* könyvtárt használok, amit az erre építő *ttkbootstrap* könyvtárral egészítek ki. A felhasználói felület forráskódja az *app.views* csomagban és az *app.widgets* modulban található.

A *tkinter* könyvtárban a GUI elemeket widgeteknek hívják. Az applikáció widgetei az *app.widgets* modulban vannak definiálva. Például az *app.widgets* modulban található a Python szintaxis kiemelését támogató szövegdoboz és az AST-ket ábrázoló fa-nézet definíciója is.

Az applikáció összetettebb nézeteit az *app.views* csomagban definiáltam. Ezek a nézetek szintén widgetek, de az *app.widgets* widgeteivel ellentétben rendelkeznek egy vezérlővel, amit a modellel való kommunikációhoz használnak (az *app.widgets* widgetei nem férnek hozzá a modellekhez).

Az *app.view* widgetei az *app.appbases.View* osztályból származnak. A *View* osztály egy *tkinter*-es frame, ami a nézethez tartozó vezérlő példányával jön létre. Az alkalmazásban három ilyen vezérlővel rendelkező nézet van, ezek osztálydiagrammait a 3.10. ábrán láthatjuk.

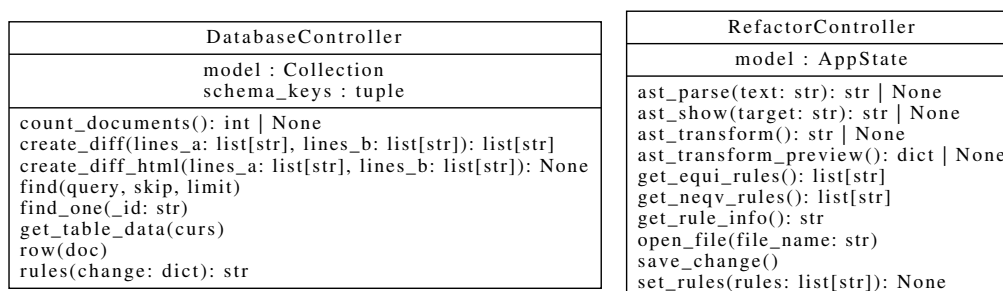


3.10. ábra. A nézetek osztálydiagrammjai

3.5.3. Vezérlők

A vezérlők feladata a kommunikáció a modellek és nézetek között. Ahogy azt a 3.10. ábrán láthatjuk csak az alkalmazás két fő nézete (*DatabaseTab* és *RefactorTab*) illetve a menü (*Menu*) rendelkeznek vezérlővel.

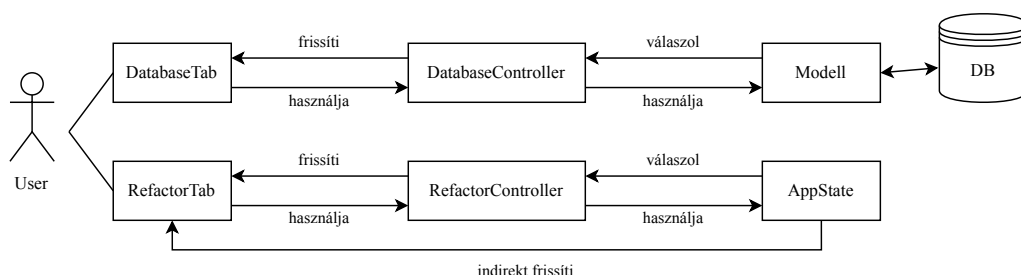
Az applikációban két különböző vezérlő van. A *DatabaseController* az adatelérési modellekkel, a *RefactorController* az alkalmazás állapotmodelljével kommunikál.



3.11. ábra. A vezérlők osztálydiagrammjai

Ha a nézeten olyan GUI esemény, történik aminek az eseménykezelője a modell vagy az állapotmodell használatát igényli, akkor az eseménykezelő a nézethez tartozó vezérlő megfelelő metódusát hívja meg. Ha az eseményhez input is tartozik (pl. egy szöveges doboz tartalma) akkor azt is továbbítja a vezérlő metódusának paraméterként.

A vezérlő használja a modellt, lekérdezéseket vagy változtatásokat végez rajta, ha ezek megtörténtek a nézetet direk vagy indirekt módon frissíti. Direkt módon frissíti, ha a modelltől kapott adatokat a nézetnek továbbítja, ami azokkal frissül. Ha a vezérlő egy eseményt vált ki a modellben, aminek hatására a nézet frissül, akkor indirekt frissíti. Ezt a működést a 3.12. ábrán láthatjuk.



3.12. ábra. Egy esemény kezelése az alkalmazás architektúrájában

Az alkalmazásban csak a *RefactorController* végez indirekt frissítést a 3.5.1. alcím alatt részletezett *Observable* tervezési minta segítségével.

3.6. Modulok

A csomagok a *tests* csomagon kívül nem tartalmaznak futtatásra szánt fájlokat. A belépési pontok és segédfüggvények a 3.4. táblázatban látható modulokba vannak szervezve.

Modul	Rövid leírás
<i>launch</i>	GUI alkalmazás belépési pontjának modulja
<i>persistor</i>	CLI program modulja
<i>tools</i>	modul eszközök alkalmazására (pl. linterek)
<i>utils</i>	utility függvények modulja (pl. fájlok olvasásához)

3.4. táblázat. A szoftver fő moduljai

A *lanuch* modul *main* függvénye a GUI alkalmazást példányosítja. A *persistor* modulban az adathalmazt generáló CLI program implementációja található.

A *tools* és *utils* modulok segédfüggvények definícióit tartalmazzák, a *ruff* lintert alkalmazó függvények például a *tools* modulban, az IO műveleteket végző függvények pedig a *utils* modulban találhatóak.

3.7. Tesztelés

Az átalakító szabályok tesztelését *unittest* modulban írt egységtesztekkel végzem. Az egységtesztek mellett az átalakítások tesztelésére a *QuixBugs* benchmarkot [12] is felhasználtam.

3.7.1. Egységtesztek

Az egységtesztek forráskódját a *tests.unit* csomag `__main__` moduljában találjuk. A tesztek futtatásához a modul *main* függvényét kell meghívni.

A teszteseteket a *unittest.TestCase*-ből származó osztályok reprezentálják. Egy tesztesethez több teszt is tartozik, ezek a teszteset osztályának metódusai. A teszteseteket és a hozzájuk tartozó teszteket a 3.5. táblázatban láthatjuk.

Egy teszt string literálként előre megadott forráskódokon alkalmaz egy szabályt. Ha a szabály alkalmazása után a kapott eredmény egyezik az elvárt eredménnyel (lásd 3.5. táblázat *Eredmény* oszlopa), akkor a teszt sikeres.

Egységtesztek		
Teszt	Rövid leírás	Eredmény
TestForRules teszteset:		
<code>test_for_to_dict</code>	<i>ForToDictComprehension</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
<code>test_for_to_list</code>	<i>ForToListComprehension</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
<code>test_for_to_set</code>	<i>ForToSetComprehension</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
<code>test_for_to_sum</code>	<i>ForToSum</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
<code>test_name_count</code>	<i>For</i> node-ban található <i>Name</i> node-ok számára vonatkozó feltétel tesztelése	a feltételnek megfelelő kódok átalakulnak
<code>test_control_flow</code>	<i>Assign</i> node és <i>For</i> node közötti node-okra vonatkozó feltétel tesztelése	a feltételnek megfelelő kódok átalakulnak

Teszt	Rövid leírás	Eredmény
TestSimpleRules teszteset:		
test_invert_if	<i>InvertIf</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
test_single_if	<i>SingleIf</i> szabállyal felismert <i>If</i> node else ágra vonatkozó feltétel tesztelése	a feltételnek megfelelő kódok átalakulnak
test_de_morgan	<i>DeMorgan</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
test_better_neg	<i>BetterNegation</i> szabály alkalmazása átalakítható kódokon	a kódok helyesen átalakulnak
test_double_neg	<i>DoubleNegation</i> szabállyal felismert <i>UnaryOp</i> operandusaira vonatkozó feltétel tesztelése	a feltételnek megfelelő kódok átalakulnak
test_tuple_assign_1	<i>TupleAssign</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_tuple_assign_2	<i>TupleAssign</i> szabály alkalmazása nem megfelelő értékadást tartamazó kódon	nincs átalakítás
test_mult_assign_1	<i>MultipleAssign</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_mult_assign_2	<i>MultipleAssign</i> szabály alkalmazása nem megfelelő értékadást tartamazó kódon	nincs átalakítás
TestProbabilityRules teszteset:		
test_commut_mult_1	<i>CommutativeMult</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_commut_mult_2	<i>CommutativeMult</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_commut_mult_3	<i>CommutativeMult</i> szabály alkalmazása két nem <i>Constant</i> node közti szorzásra	nincs átalakítás

Teszt	Rövid leírás	Eredmény
test_insert_continue	<i>InsertContinue</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_insert_pass	<i>InsertPass</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
TestNonEquivalentRules tesztet:		
test_negate_if	<i>NeqvNegateIf</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_invert_if	<i>NeqvInvertIf</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_swap_and_or	<i>NeqvSwapAndOr</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_swap_add_sub	<i>NeqvSwapAddSub</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul
test_insert_return	<i>NeqvInsertReturn</i> szabály alkalmazása egy átalakítható kódon	a kód helyesen átalakul

3.5. táblázat. Egységtesztek táblázata

3.7.2. Tesztelés a *QuixBugs* segítségével

A *QuixBugs* benchmark 40 közismert algoritmus Java és Python implementációját tartalmazza. Minden algoritmushoz található egy helyes és egy helytelen (bugos) implementáció. Az algoritmusok helyes implementációihoz tartoznak validáló tesztek is. A benchmark eredeti célja a forráskód-javításra képes eszközök tesztelése, de a benchmarkot használhatjuk forráskódokon végzett átalakítások tesztelésére is.

A benchmark segítségével az általam implementált összes szabályt tesztelem. Ehhez az algoritmusok forráskódjait előbb átalakítom a szabályok alapján, majd futtatom a *QuixBugs* tesztéseit az átalakított kódokon.

Az ekvivalens szabályok helyességét úgy ellenőrzöm, hogy az összes ekvivalens szabályt alkalmazom a *QuixBugs* kódjain. Az összes ekvivalens szabály által végzett átalakítások nem ronthatnak el egy kódot sem, vagyis az átalakított kódokon futtatott összes teszt eredménye sikeres kell legyen. Azt is tesztelem, hogy a nem ekvivalens szabályok képesek-e elrontani egy kódot, vagyis úgy átalakítani azt, hogy a hozzá tartozó tesztek elbukjanak.

A benchmarkot használó teszteket a *tests.quix* csomag `__main__` moduljában található *main* függvénnyel futtathatjuk. A tesztek futtatásához szükségünk van a *QuixBugs* szoftvertárolóra, a *main* függvényt a szoftvertároló elérési útvonalával kell meghívni.

A teszteteket a *test_transformations* függvény futtatja, ez a függvény teszteli az általam implementált összes ekvivalens és nem ekvivalens szabályt. Az alkalmazott szabályok ekvivalenciáját az *equivalent* boolean paraméterrel lehet megadni.

A *test_transformations* által végzett teszteknek két fázisa van. A függvény először a cache-eli az összes helyes megoldást tartalmazó forráskódot, ezután átalakítja a forráskódokat és futtatja a *QuixBugs* tesztjeit. Ha a tesztek lefutottak a cache-elt kódok felülírják az átalakított kódokat, így újraindíthatjuk a tesztet.

A *QuixBugs*-os teszteket többször is futtattam, a tesztek eredményeit a 3.6. táblázatban láthatjuk. A táblázat egy sora egy teszt eredményeit tartalmazza.

Az első két oszlopban a sikeres tesztek és végzett tesztek számának százalékos aránya (*Pass%*) szerepel ekvivalens és nem ekvivalens szabályok alkalmazása után. Egy

tesztet akkor tekintik sikeresnek, ha ekvivalens szabályok esetén a *Pass%* 100, vagyis ha az ekvivalens szabályok nem rontanak el egy kódot sem.

Pass% ekvivalens szabályoknál	Pass% nem ekvivalens szabályoknál
276 / 276 = 100%	31 / 276 \approx 11%
276 / 276 = 100%	23 / 276 \approx 8%
276 / 276 = 100%	30 / 276 \approx 10%
276 / 276 = 100%	14 / 276 \approx 5%
276 / 276 = 100%	26 / 276 \approx 9%

3.6. táblázat. *QuixBugs* benchmarkot használó tesztek eredményei

A 3.6. táblázatban látható, hogy a nem ekvivalens szabályok alkalmazása után a kódok nagy része nem megy át a teszteseteken. A nem ekvivalens szabályok esetében az eredmények azért különböznek, mert a szabályok alkalmazásának alap valószínűsége kisebb mint 1, ezért az összes nem ekvivalens szabályt alkalmazó függvény nem determinisztikus.

Fontos megjegyezni, hogy az átalakítás során az nem biztos, hogy az összes ekvivalens szabály alkalmazásra kerül. Ezért érdemes lehet a *QuixBugs*-hoz hasonló, de nagyobb terjedelmű benchmarkon is tesztelni az átalakításokat.

4. fejezet

Összegzés

Szakdolgozatomban egy ekvivalenciát eldöntő neuronháló tanító adathalmazának generálásához fejlesztettem szoftvert. Az adathalmaz ekvivalenciával felcímkézett Python forráskód-párokat tartalmaz.

Az adathalmazban szereplő forráskód-párok generálásához egy olyan AST-szintű átalakító szoftvert implementáltam, ami képes Python kódokon ekvivalens és nem ekvivalens változtatásokat végezni. Az átalakító szoftver segítségével GitHub-ról bányászott kódokból generáltam ekvivalens és nem ekvivalens forráskód-párokat tartalmazó adathalmazt.

Az átalakítások szemléltetésére grafikus felhasználói felületű asztali alkalmazást is készítettem, amivel a felhasználó kipróbálhatja az átalakításokat.

A szoftver forráskódja alapvetően objektum orientált. A megvalósítás során a bővíthetőségre törekedtem. A meglévő interfészekkel új átalakításokat adhatunk a szoftverhez, az MVC architektúrának köszönhetően pedig a GUI alkalmazás nézeteit is könnyen lecserélhetjük.

A tanító adathalmazt érdemes lehet GitHub-os kódokon kívül más forráskódok alapján generálni. Az adathalmaz generálására a project-codenet [13] adathalmaz például egy jó kiinduló pont lehet.

A jövőben a szoftvert több szempontból is bővíteni fogom, különös tekintettel az adathalmaz generálására, illetve a neuronháló tanítására és kiértékelésére.

Köszönetnyilvánítás

Szeretném kifejezni köszönetemet mindazoknak, akik hozzájárultak szakdolgozatom elkészítéséhez és sikeres befejezéséhez.

Köszönettel tartozom témavezetőmnek, Szalontai Balázsnak, aki türelmével és folyamatos támogatásával segített a szakdolgozat megírásában. Iránymutatása és tanácsai nélkül a dolgozat nem valósulhatott volna meg.

Ugyanakkor köszönetet szeretnék mondani kutatócsoportom minden tagjának, különösen Márton Tamásnak, aki az általa írt program forráskódjának megosztásával segített az adatgyűjtésben.

Irodalomjegyzék

- [1] Liuqing Li és tsai. „CCLearner: A Deep Learning-Based Clone Detection Approach”. *2017 IEEE International Conference on Software Maintenance and Evolution (ICSME)*. 2017, 249–260. old. DOI: 10.1109/ICSME.2017.46.
- [2] Gang Zhao és Jeff Huang. „DeepSim: deep learning code functional similarity”. *Proceedings of the 2018 26th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering*. Association for Computing Machinery, 2018, 141–151. old. DOI: 10.1145/3236024.3236068. URL: <https://doi.org/10.1145/3236024.3236068>.
- [3] Aditya Kanade és tsai. „Learning and evaluating contextual embedding of source code”. *Proceedings of the 37th International Conference on Machine Learning*. JMLR.org, 2020.
- [4] Paras Jain és tsai. „Contrastive Code Representation Learning”. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021. DOI: 10.18653/v1/2021.emnlp-main.482. URL: <http://dx.doi.org/10.18653/v1/2021.emnlp-main.482>.
- [5] python docs. *ast - Abstract Syntax Trees*. URL: <https://docs.python.org/3/library/ast.html>.
- [6] ruff docs. *Ruff*. URL: <https://docs.astral.sh/ruff/>.
- [7] mongodb docs. *MongoDB Installation*. URL: <https://www.mongodb.com/docs/manual/installation/>.
- [8] Verebics Péter. *API dokumentáció*. URL: http://szonyegxddd.web.elte.hu/szakdolgozat_api_doc/index.html.
- [9] Berker Peksag. *astor - AST observe/rewrite*. URL: <https://astor.readthedocs.io/en/latest/#>.

- [10] VasileAlaiba. *Monostate Pattern*. 2014. URL: <https://wiki.c2.com/?MonostatePattern>.
- [11] Cristina V. Lopes és tsai. „DéjàVu: a map of code duplicates on GitHub”. (2017). DOI: 10.1145/3133908. URL: <https://doi.org/10.1145/3133908>.
- [12] Derrick Lin és tsai. „QuixBugs: a multi-lingual program repair benchmark set based on the quixey challenge”. (2017). DOI: 10.1145/3135932.3135941. URL: <https://doi.org/10.1145/3135932.3135941>.
- [13] Ruchir Puri és tsai. „Project CodeNet: A Large-Scale AI for Code Dataset for Learning a Diversity of Coding Tasks”. 2021.

Ábrák jegyzéke

2.1. A CLI alkalmazás futás közben	6
2.2. Az alkalmazást indító ablak	7
2.3. Refaktoráló nézet az indítás után	8
2.4. Hibákat jelző párbeszéd-ablakok	8
2.5. Példa egy átalakítás eredményére	9
2.6. A <i>helloworld</i> program AST-je	10
2.7. Adatbázis-böngésző nézet	11
3.1. A <i>SimpleRule</i> osztály	17
3.2. A <i>TSimple</i> átalkító osztály	19
3.3. A <i>ForRule</i> osztály	22
3.4. A <i>TFor</i> átalakító osztály	24
3.5. A <i>For</i> szabályok UML diagramja	24
3.6. A <i>Client</i> osztály UML diagramja	26
3.7. A model csomag osztályainak UML diagramjai	27
3.8. Az alkalmazás csomagjai	28
3.9. Állapotmodell és kapcsolódó osztályok UML diagramjai	29
3.10. A nézetek osztálydiagrammjai	31
3.11. A vezérlők osztálydiagrammjai	31
3.12. Egy esemény kezelése az alkalmazás architektúrájában	32

Táblázatok jegyzéke

2.1. Adatbázis-böngésző nézet táblázatának oszlopai	11
3.1. A szoftver fő csomagjai	12
3.2. Ekvivalens <i>In-place</i> szabályok táblázata	20
3.3. Nem ekvivalens <i>In-place</i> szabályok táblázata	20
3.4. A szoftver fő moduljai	32
3.5. Egységtesztek táblázata	35
3.6. <i>QuixBugs</i> benchmarkot használó tesztek eredményei	37

Forráskódjegyzék

3.1. A <i>NameVisitor</i> osztály kódja	14
3.2. A <i>TypeVisitor</i> osztály kódja	15
3.3. Példa megoldása for ciklussal	21
3.4. Példa megoldása comprehensionnel	21