Eötvös Loránd Tudományegyetem

Informatikai Kar

Programozáselmélet és Szoftvertechnológiai Tanszék

Ekvivalens Python forráskód-párok generálása

Témavezető:
Szalontai Balázs
doktorandusz

Szerző:
Verebics Peter
programtervező informatikus BSc

Budapest, 2024

Tartalomjegyzék

1. fejezet

Bevezetés

Szakdolgozatom témája Python forráskódok átalakítása és ezen átalakítások szemléltetése. A motiváció az átalakítások mögött egy olyan adathalmaz generálása amiben ekvivalens és nem ekvivalens forráskód-párok egyaránt szerepelnek. Egy ilyen adathalmazt felhasználhatunk egy mélytanuló neuronháló tanítására, ami forráskód-párok ekvivalenciáját dönti el.

Az ekvivalencia eldöntése fontos feladat, mivel egyre több, kódokat gépi tanulással refaktoráló, eszköz létezik. Ezek az eszközök egy kódot változtatva sokszor a kód jelentését is megváltoztatják. Egy ekivalenciát eldöntő neuronháló képes lenne kiszűrni az ilyen eszközök által generált rossz eredményeket, javítva az eszközök hatékonyságán.

Tehát ekvivalens és nem ekvivalens kódokat generálva felépíthetünk egy adathalmazt, ami ekvivalenciával felcímkézett kódpárokat tartalmaz, és alkalmas egy fent leírt neuronháló tanítására.

Az általam implementált átalakítások absztrakt szintaxisfák (AST-k) módosításával működnek. Egy forráskód fordítása alatt a szemantikus elemző előállítja a kód AST-jét, ami a kódot egy fa adatstruktúrával reprezentálja. Az AST-nek a szemantikus elemzésben van szerepe, de használhatjuk kódok átalakítására is, mivel vissza lehet alakítáni forráskóddá.

Az általam megvalósított átalakítások a Python *ast* modulját használják, ami része a Python standard könyvtárának. Az *ast* modul lehetőséget biztosít egy Python kód AST-vé és AST kóddá alakítására is.

Az átalakításokat szabályok végzik. Átalakításkor a Python kódból létrehozott AST-n végrehajthatunk egy szabályt. A szabály megváltoztatja az AST-t, amit ha

visszaalakítunk kóddá egy megváltozott Python kódot kapunk.

A szakdolgozatomban ekvivalens és nem ekvivalens szabályokat is definiálok. Egy szabály akkor tekinthető ekvivalensnek, ha a kód szemantikáját nem változtatja meg. Például a Python-ban is teljesül a valós számok körében a szorzás kommutatív tulajdonsága. Tehát ha egy Python kódban két szám szorzásánál a bal és jobb operandust megcseréljük, akkor a szorzás eredménye nem változik, vagyis ez az átalakítás ekvivalens. Ez a példa természetesen nagyon egyszerű, a szakdolgozatomban összetettebb átalakításokra is adok példát.

Az adathalmazban az ekvivalens kódok generálásához saját szabályok mellett, a *ruff* Python linter és formatter szabályait is felhasználtam. A *ruff* már létező Python lintereket implementál Rust programozási nyelven, így sok más Python refaktoráló eszköz szabályait is képes elvégezni, amik tökéletesek az általam implementált szabályok kiegészítésére.

A szakdolgozatom következő fejezeteiben az adathalmaz generálására és az átalakítások szemléltetésére alkalmas szoftver használatát és működését részletezem.

2. fejezet

Felhasználói dokumentáció

A szoftver két felhasználói felülettel rendelkezik. Az egyik egy parancssoros (CLI) program az adathalmaz generálásához, a másik egy grafikus (GUI) alkalmazás az átalakítások szemléltetéséhez és az adathalmaz böngészéséhez. Mindkét alkalmazás felületének nyelve angol.

2.1. Futtatási környezet

Mivel a Python egy iterpretált programozási nyelv a szoftver legegyszerűbben a forráskód könyvtárából futtatható, ez a szoftver git repójának *dataset* könyvtára, de a következőkben az egyszerűség kedvéért mint **forrás** könyvtár fogok rá hivatkozni.

A szoftver egy Python 3.10-es vagy újabb verziójú Python interpreterrel futtatható. A futtatáshoz a függőségeket installálni kell a pip csomagkezelővel. A függőségek a forrás könyvtárában, a *requirements.txt* fájlban találhatók, és a következő paranccsal installálhatók:

```
1  $ pip install -r requirements.txt
```

2.2. Adatbázis beállítása

A szoftvernek az adathalmaz generálásához szüksége van egy *mongodb* adatbázisra. Az adatbázis kiszűri a kódpárok generálása közben a duplikált kódokat és az adatok lekérdezését is megkönnyíti. Azért döntöttem a *mongodb* mellett, mert az SQL adatbázisoknál sokkal flexibilisebb. A *monogodb* telepítéséről következő linken olvashatunk [1].

Az adatbázis elérést a forrás könyvtárában a *config/default.ini* útvonal alatt található konfigfájlban lehet beállítani. Egy adatbázist három paraméter határoz meg: *host*, *port*, *database* (az adatbázis neve). Ha szükség van rá a konfigfájl alapértékeit átírhatjuk.

2.3. Adathalmazt generáló CLI

Ezzel a CLI alkalmazással van lehetőségünk az adathalmaz generálására egy adott csv fájlban található kódokból vagy egy könyvtárban taláható forrásfájlokból. Adathalmazt a következő paranccsal generálhatunk:

```
1  $ python -m source.persistor <mode> <path>
```

A parancs paraméterei a következők:

1. *mode* - az adatok forrásának típusa, lehetséges értékek:
   - *csv* - csv fájlból olvassa a forrásfájlok tartalmát
   - *dir* - könyvtárból rekurzívan olvassa a forrásfájlokat
2. *path* - az adatok forrásának elérési útvonala

Ha megadtuk a parancsot a program megpróbálja a forráskódok olvasását, ha az input nem megfelelő leáll.

Futás közben a program a kiírja az éppen feldolgozott forráskóddal kapcsolatos információkat, például a kódon végzett átalakítások számát és azt, hogy el tudta-e menteni az átalakítások eredményeit.

```
reading csv, be patient this might take a while...
-------------------------------------------------------------------------------------------------[0]
No changes to save.
-------------------------------------------------------------------------------------------------[1]
Fixed 13 errors.
1 file reformatted
1 file reformatted
1 file reformatted
Inserted 3 changes on hash f3842737e0fe9141df61f299c99e65d9b20a41ae3c76644ef663483aec8aeb31.
-------------------------------------------------------------------------------------------------[2]
Fixed 12 errors.
1 file reformatted
1 file reformatted
1 file reformatted
Inserted 3 changes on hash bdd72cdcf458519e9e88afa499c0e6363e427fa7ea8c9fe5484a426babed40c1.
```

2.1. ábra. A CLI alkalmazás futás közben

Ha a program végigolvasta a csv fájlt vagy a könyvtárban található forrásfájlokat leáll. Miután a program leállt a forráskód-párok már az adatbázisban vannak. A *mongoexport* eszköz segítségével az adatbázisból a forráskód-párokat egy csv fájlba exportálhatjuk.

2.4. Átalakításokat szemléltető GUI

Ez a GUI alkamazás szemlélteti az átalakításokat. Kipróbálhatunk vele egy vagy több átalakító szabályt, vizualizálhatjuk kódok absztrakt szintaxis fáját, és az adatbázisba bekerült átalakítások eredményét is megnézhetjük.

2.4.1. Alkalmazás indítása

Az alkalmazás a forrás könyvtárából indítható a következő paranccsal:

```
1  $ python -m source
```

A parancs kiadása után felugró ablakban beállíhatjuk az adatbázis kapcsolathoz szükséges paramétereket: a *host*, *port* illetve *database* értékeit. A *Connect* gombra kattintva az alkalmazás adatbáziseléréssel indul, ha a megadott adatbázishoz 10 másodperc alatt kapcsolódni tud, különben adatbáziselérés nélkül. Adatbáziselérés nélkül a *Launch Now* gombbal indíthatjuk az alkalmazást.

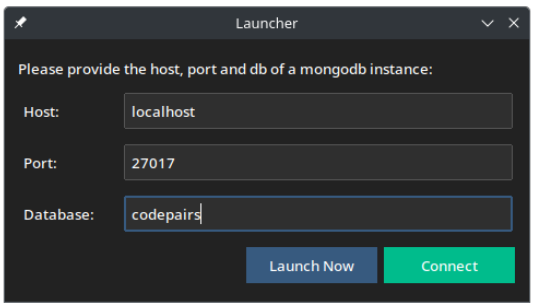

2.2. ábra. Az alkalmazást indító ablak

2.4.2. Alkalmazás felülete

Az alkalmazás felülete funkciók szerint két fő nézetre osztható, a refaktoráló és az adatbázis-böngésző nézetre. A refaktoráló nézetben (*Refactor* tab) egy kódon ekvivalensen és nem ekvivalensen átalakító szabályokat próbálhatunk ki, és elmenthetjük a szabályok által végzett átalakítások eredményeit. Az adatbázis-böngésző

(*Database* tab) nézetben az adatbázisba bekerült kódpárokat tekinthetjük meg. A fájlok olvasásáért, az AST-k gráfos ábrázolásáért és a segítségért felelő gombok, illetve a beállításokat mutató állapotsor a két fő nézeten kívül helyezkednek el.

2.4.3. Refaktoráló nézet

Indítás után a felhasználót a refaktoráló nézet fogadja. Egy Python forráskód átalakításához a kódot begépelhetjük a *Source Code* szöveges input mezőbe, vagy egy *.py* fájlból is betölthetjük a menüben látható *Open File* gombra kattintva.

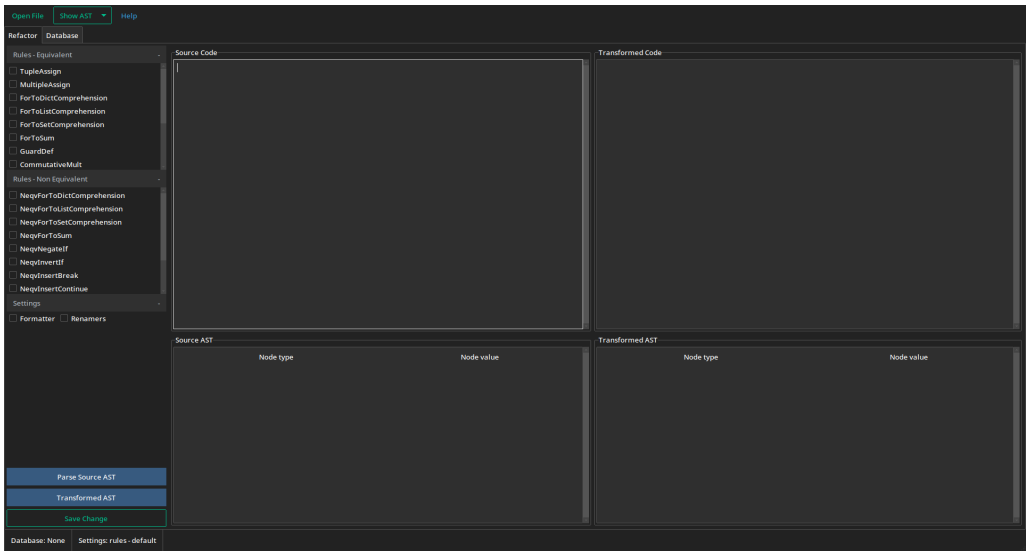

2.3. ábra. Refaktoráló nézet az indítás után

Az átalakítás előtt a begépelt vagy betöltött forráskódból az elemező (parser) futtatásával létre kell hozni egy AST-t, ezt a *Parse Source AST* gombbal tehetjük meg. Ha a megadott forráskódban szintaxis hiba található, vagy valami egyéb okból kifolyólag nem elemezhető, akkor az alkalmazás ezt jelzi egy felugró párbeszéd-ablakkal. Akkor is jelez ha parse-olás nélkül klikkelünk az átalakító gombra.

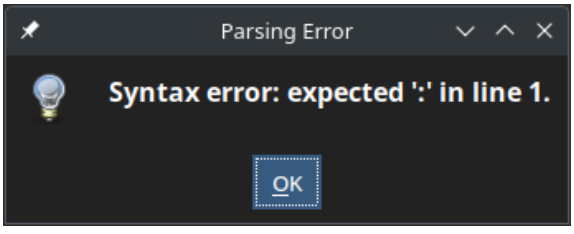

(a) elemzési hiba esetén

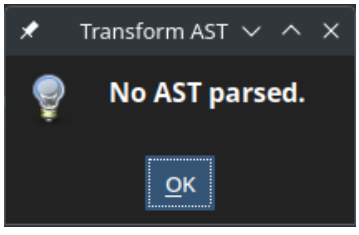

(b) hiányzó AST esetén

2.4. ábra. Hibákat jelző párbeszéd-ablakok

Sikeres elemzés után az AST felépítését a *Source AST* fa-nézeten láthatjuk, az első oszlopban a csúcs típusa, a második oszlopban a csúcs szintaxis fájából generált kód látható. Elemzés után a fát átalakíthatjuk a *Transform AST* gombra kattintva, ekkor az átalakított fa megjelenik a bal oldali *Transformed AST* fa-nézeten, az átalakított fából generált kód pedig a *Transformed Code* readonly szövegdobozban.

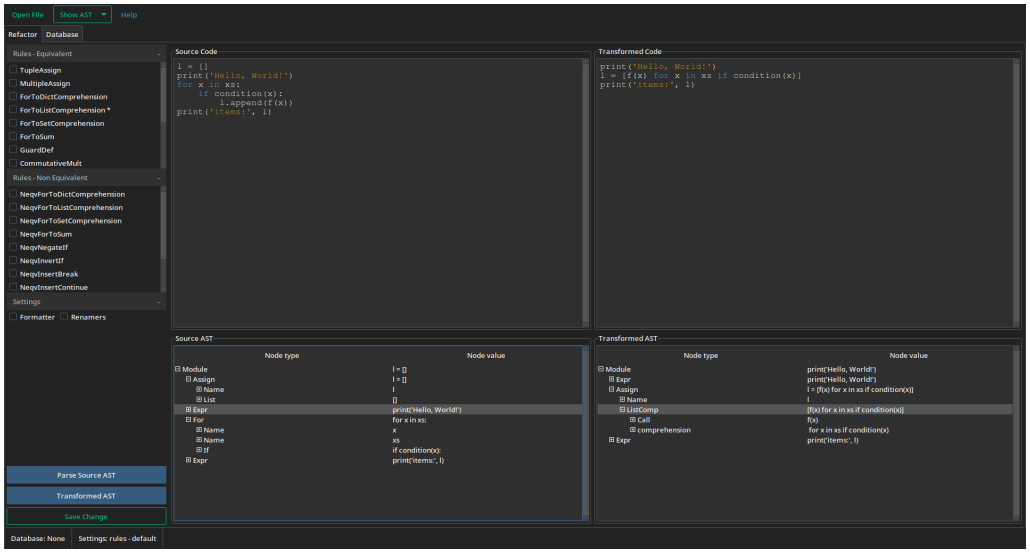

2.5. ábra. Példa egy átalakítás eredményére

Az alkalmazásba összesen 28 átalakító szabály van, ezek közül 16 ekvivalens és 12 nem ekvivalens eredményt állít elő. Az alkalmazás indításakor az összes ekvivalens szabály ki van választva, ez az alkalmazás alapbeállítása amit a *'rules - default'* felirat jelez az állapotsorban.

Lehetőségünk van általunk választott szabályok alkalmazására is. A szabályok listája a bal oldali panelen látható. Minden szabály előtt van egy checkbox amivel a szabályt kiválaszthatjuk. Lehetőségünk van egy vagy több szabály kiválasztására is, így könnyen tesztelhetjük egy szabály működését is. Ha vannak kiválasztott szabályok azt a *'rules - custom'* felirat jelzi az állapotsorban.

Átalakításkor a szabályok a bal oldali panelen látható sorrendben, fentről lefele kerülnek végrehajtásra. A panelen a szabályokon kívül található még két checkbox is, ezekkel a *ruff* formatter és az átnevező szabályok alkalmazását tudjuk beállítani.

Miután átalakítottunk egy forráskódot kimenthetjük az átalakítás eredményét az adatbázisba (ha van adatbázis kapcsolat). Ezt a refaktoráló nézet bal alsó sarkában elhelyezkedő *'Save Change'* gombbal tehetjük meg. Ha az átalakítást nem lehet elmenteni azt az alkalmazás párbeszéd-ablakban jelzi.

2.4.4. AST-k vizualizálása fagráffal

Az alkalmazás fagráfként is tud AST-ket vizualizálni. Az általunk megadott vagy átalakított kód AST-jének fagráfját a menüben látható *Show AST* lenyíló menügombbal vizualizálhatjuk. A gombra klikkelve két opció közül választhatunk: a *Source* gomb az általunk megadott kód, a *Transformed* gomb pedig az átalakított kód AST-jét vizualizálja, ha ezek léteznek. Az alkalmazás az elkészült fagráf ábráját egy felugró ablakban nyitja meg. Az alábbi ábrán például a *helloworld* Python kódjának AST-jét láthatjuk:

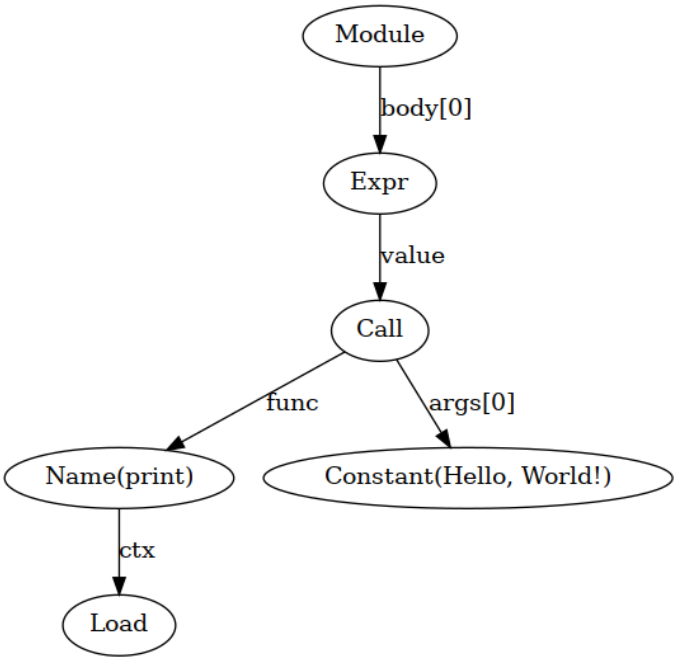

2.6. ábra. A *helloworld* program AST-je

2.4.5. Adatbázis-böngésző nézet

Ebben a nézetben megtekinthetjük az adatbázisba bekerült forráskód-párokat. A nézet csak akkor jön létre ha az alkalmazásnak van adatbázis elérése, ha nincs azt a nézeten a *"No database connection."* felirat jelzi. A nézet feladata a forráskód-párok listázása és a párba állított forráskódok különbségeinek megjelenítése.

A különbségeket két forráskód között könnyen vizualizálhatjuk egy diffel, egy olyan szövegösszehasonlító programmal ami két szöveg között a különbségek listáját állítja elő. A különbségeket a forráskód-párokban ezzel a módszerrel vizualizálom.

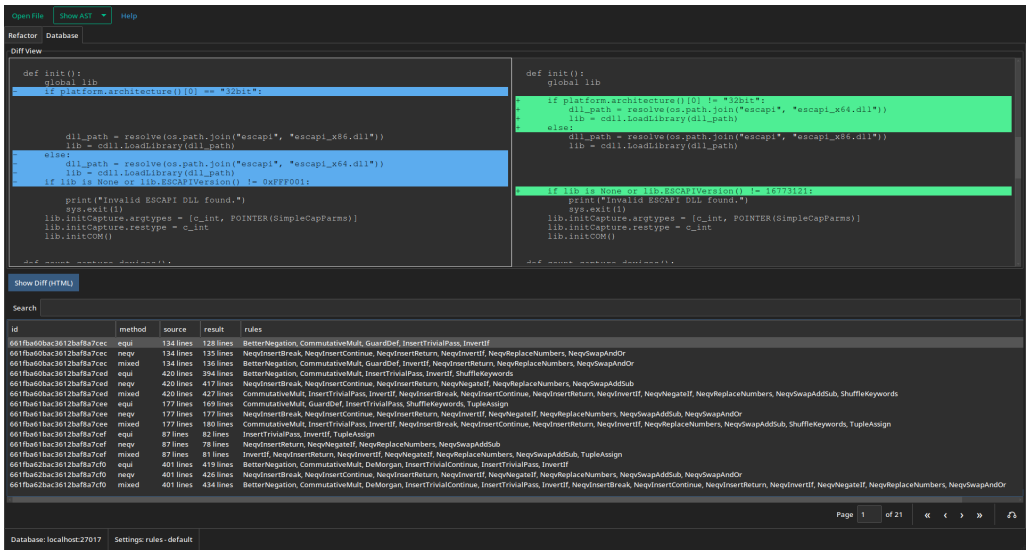

2.7. ábra. Adatbázis-böngésző nézet

A nézet tetején találhatók a diffeket megjelenítő szövegdobozok, ezek alatt egy táblázat látható, soraiban az adatbázisba bekerült forráskód-párokkal. A táblázat soraiban található adatok sémáját az alábbi táblázat írja le:

Oszlop	**Típus**	**Magyarázat**
id	object id	az eredeti forrráskód azonosítója
method	string	az átalakításra használt módszerre utal (például a szabályhalmazra)
source	string	az eredeti forráskód sorainak száma
result	string	az átalakított forráskód sorainak száma
rules	string	az átalakításnál alkalmazott szabályok listája

2.1. táblázat. Adatbázis-böngésző nézet táblázatának oszlopai

Ha a táblázat egy sorára, vagyis egy forráskód-párra klikkelünk akkor a diff nézetben megjelennek az eredeti (bal oldali) és átakított (jobb oldali) kód közti különbségek.

A táblázat felleti keresőt használathatjuk a forráskód-párok böngészéséhez. A kereső az összes sorban és oszlopban szereplő adatok közt keres. Például megkereshetjük, hogy az adatbázisban mely forráskódokon kerültek for ciklussal kapcsolatos átalakítások alkalmazásra.

3. fejezet

Fejlesztői dokumentáció

TODO: intro

3.1. Csomagok

A szoftver forráskódja több csomagban és modulban található. A forrráskód jelentős része öt fő csomagba van szerveze, ezek az alábbi táblázatban láthatók.

Csomag	**Rövid leírás**
app	GUI alkalmazás csomagja
client	adatbázis kliens
model	adatok modelezése és mentése
tests	egység és egyéb tesztek
transformations	átalakítások forráskódja és API az átalakításokhoz

3.1. táblázat. A szoftver fő csomagjai

Minden csomag a szoftver egy jól elkülöníthető részét vagy funkcióját valósítja meg. A fő csomagok (a *tests* csomag kivételével) nem tartalmaznak "futtatható" fájlokat, a belépési pontok külön modulokba vannak szervezve.

3.2. *app* csomag

Az *app* csomag feladata az átalakításokat szemléltető GUI-s alkalmazás megvalósítása. Az alkalmazás architektúrája model-nézet-kontroller (MVC) szerű. Egy nézet rendelkezik egy kontrollerrel és a kontroller pedig egy modellel.

A nézet feladata a GUI definiálása és frissítése, a model feladata az adatelérés vagy az alkalmazás állapotának modelezése. A kontroller ezt a két réteget köti össze, így a nézet nem függ a modeltől és a model sem a nézettől.

Tegyük fel, hogy a nézeten történik egy GUI esemény, például a felhasználó egy gombra klikkel, aminek az eseménykezelője a model használatát igényli. Ekkor az eseménykezelő a nézet kontrollerének továbbítja a megfelelő adatokat. A kontroller használja a modelt, majd a nézetet direk vagy indirekt módon frissíti. Direkt módon frissíti, ha a modeltől kapott adatokat a nézetnek továbbítja, ha pedig egy eseményt vált ki a modelben aminek hatására a nézet frissül akkor indirekt frissíti. Ezt a működést az alábbi ábrán láthatjuk.

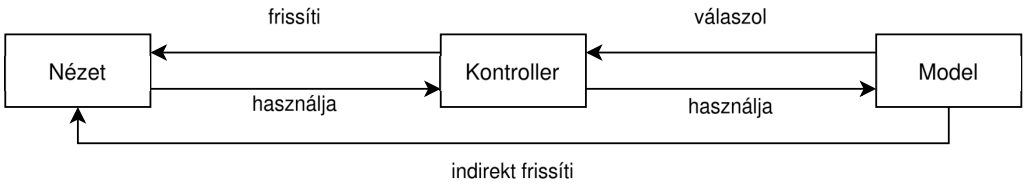

3.1. ábra. Egy esemény kezelése az MVC architektúrában

3.2.1. Állapotmodel

Az alkalmazásban kétféle model különböztethető meg: az állapot és adatelérési modelek. Az alkalmazás állapotmodelje az *app.appstate* modulban található. Az adatelérési modelek nem az alkalmazás csomagjában vannak definiálva mivel a szoftver más rétegeinek is szüksége van ezekre.

Az állapotmodel az *observer* tervezési mintát használja a nézetek frissítésére és az *AppState* osztályban van definiálva. Az *AppState* osztály az *Observable* osztályból származik, ezért rendelkezik megfigyelők (*observers*) egy listájával, ami esemény-eseménykezelő párok listája.

Ha a nézet egy komponenesét az állapotmodel változásának hatására akarjuk frissíteni, akkor azt az eseménykezelőt, ami frissíti, hozzárendelhetjük az állapotmodel egy eseményéhez.

Hozzárendelni egy eseménykezelőt egy eseményhez az *Observable* osztály *attach* metódusával lehet. Ha az adott eseményt kiváltja egy változás a modelben, akkor a model értesíti a nézeteket, vagyis az *observers*-ben az eseményéhez rendelt eseménykezelőket meghívja, a frissítéshez szükséges adatokat paraméterként továbbítva.

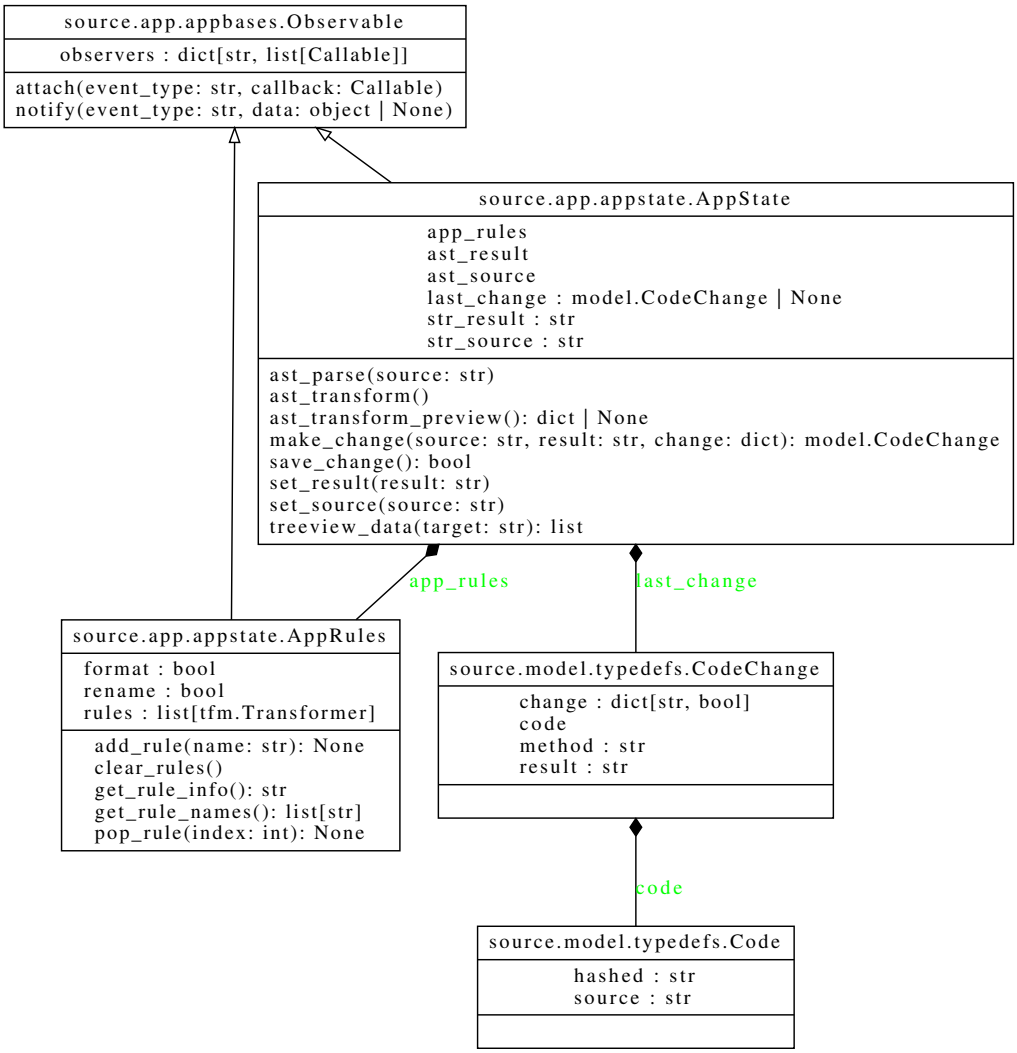

3.2. ábra. Állapotmodel UML diagramja

A felhasználói felület (View-réteg) kódja a *app.views* csomagban található, a Python-ban alapból megtalálható *tkinter* könyvtárt használja, amit az erre építő *ttkbootstrap* könyvtárral egészít ki.

A kontrollerek feladata a kommunikáció a modelek és nézetek között. Csak a felhasználói felület két fő nézete a *RefactorTab* és a *DatabaseTab* rendelkeznek saját kontrollerekkel.

4. fejezet

Összegzés

Lorem ipsum dolor sit amet, consectetur adipiscing elit. In eu egestas mauris. Quisque nisl elit, varius in erat eu, dictum commodo lorem. Sed commodo libero et sem laoreet consectetur. Fusce ligula arcu, vestibulum et sodales vel, venenatis at velit. Aliquam erat volutpat. Proin condimentum accumsan velit id hendrerit. Cras egestas arcu quis felis placerat, ut sodales velit malesuada. Maecenas et turpis eu turpis placerat euismod. Maecenas a urna viverra, scelerisque nibh ut, malesuada ex.

Aliquam suscipit dignissim tempor. Praesent tortor libero, feugiat et tellus porttitor, malesuada eleifend felis. Orci varius natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Nullam eleifend imperdiet lorem, sit amet imperdiet metus pellentesque vitae. Donec nec ligula urna. Aliquam bibendum tempor diam, sed lacinia eros dapibus id. Donec sed vehicula turpis. Aliquam hendrerit sed nulla vitae convallis. Etiam libero quam, pharetra ac est nec, sodales placerat augue. Praesent eu consequat purus.

Köszönetnyilvánítás

Amennyiben a szakdolgozati / diplomamunka projekted pénzügyi támogatást kapott egy projektből vagy az egyetemtől, jellemzően kötelező feltüntetni a dolgozatban is. A dolgozat elkészítéséhez segítséget nyújtó oktatók, hallgatótársak, kollégák felé is nyilvánítható külön köszönet.

A. függelék

Szimulációs eredmények

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque facilisis in nibh auctor molestie. Donec porta tortor mauris. Cras in lacus in purus ultricies blandit. Proin dolor erat, pulvinar posuere orci ac, eleifend ultrices libero. Donec elementum et elit a ullamcorper. Nunc tincidunt, lorem et consectetur tincidunt, ante sapien scelerisque neque, eu bibendum felis augue non est. Maecenas nibh arcu, ultrices et libero id, egestas tempus mauris. Etiam iaculis dui nec augue venenatis, fermentum posuere justo congue. Nullam sit amet porttitor sem, at porttitor augue. Proin bibendum justo at ornare efficitur. Donec tempor turpis ligula, vitae viverra felis finibus eu. Curabitur sed libero ac urna condimentum gravida. Donec tincidunt neque sit amet neque luctus auctor vel eget tortor. Integer dignissim, urna ut lobortis volutpat, justo nunc convallis diam, sit amet vulputate erat eros eu velit. Mauris porttitor dictum ante, commodo facilisis ex suscipit sed.

Sed egestas dapibus nisl, vitae fringilla justo. Donec eget condimentum lectus, molestie mattis nunc. Nulla ac faucibus dui. Nullam a congue erat. Ut accumsan sed sapien quis porttitor. Ut pellentesque, est ac posuere pulvinar, tortor mauris fermentum nulla, sit amet fringilla sapien sapien quis velit. Integer accumsan placerat lorem, eu aliquam urna consectetur eget. In ligula orci, dignissim sed consequat ac, porta at metus. Phasellus ipsum tellus, molestie ut lacus tempus, rutrum convallis elit. Suspendisse arcu orci, luctus vitae ultricies quis, bibendum sed elit. Vivamus at sem maximus leo placerat gravida semper vel mi. Etiam hendrerit sed massa ut lacinia. Morbi varius libero odio, sit amet auctor nunc interdum sit amet.

Aenean non mauris accumsan, rutrum nisi non, porttitor enim. Maecenas vel tortor ex. Proin vulputate tellus luctus egestas fermentum. In nec lobortis risus,

sit amet tincidunt purus. Nam id turpis venenatis, vehicula nisl sed, ultricies nibh. Suspendisse in libero nec nisi tempor vestibulum. Integer eu dui congue enim venenatis lobortis. Donec sed elementum nunc. Nulla facilisi. Maecenas cursus id lorem et finibus. Sed fermentum molestie erat, nec tempor lorem facilisis cursus. In vel nulla id orci fringilla facilisis. Cras non bibendum odio, ac vestibulum ex. Donec turpis urna, tincidunt ut mi eu, finibus facilisis lorem. Praesent posuere nisl nec dui accumsan, sed interdum odio malesuada.

Irodalomjegyzék

[1] mongodb docs. *Mongodb Installation*. URL: `https://www.mongodb.com/docs/manual/installation/`.

Ábrák jegyzéke

Táblázatok jegyzéke

Algoritmusjegyzék

Forráskódjegyzék